

Lectures dirigées - Différentes dynamiques épidémiques

Hugo Lever et Garance Malnoë dirigé.e.s par Hugo Martin

Janvier - Avril 2024

1 Introduction

Dans notre société contemporaine, les maladies telles que le VIH, la grippe et le covid font partie de notre quotidien. Depuis la crise sanitaire liée au covid, l'intérêt du grand public pour l'épidémiologie, notamment la prévision de l'évolution des épidémies, s'est considérablement renforcé. Ainsi, la compréhension et la gestion des maladies infectieuses sont devenues des préoccupations majeures, mettant en lumière le rôle crucial de l'épidémiologie dans nos sociétés. Cette discipline offre un outil à la prise de décisions publiques, par exemple pour anticiper l'impact d'un test de dépistage, d'une campagne de vaccination de masse ou encore d'une quarantaine généralisée.

Les mathématiques se trouvent au cœur de l'épidémiologie, offrant un cadre pour modéliser et comprendre les dynamiques complexes des épidémies. Dans ce rapport, nous nous attachons à modéliser mathématiquement une épidémie en cherchant à décrire et prédire l'évolution d'une vague épidémique au sein d'une population donnée. Nous cherchons ainsi à traduire des hypothèses exprimées en langage naturel en des termes mathématiques et des équations différentielles.

Notre attention se porte sur les modèles dits à compartiments, introduits pour la première fois en 1927 par Kermack et McKendrick dont le but était de modéliser *a posteriori* l'épidémie de peste de 1905-1906 à Bombay. Ces modèles consistent à diviser la population en plusieurs catégories selon leur état sanitaire et à les relier entre elles. Ils peuvent être simples avec seulement deux ou trois catégories ou bien étendus à une dizaine de catégories.

Nous commençons notre rapport par une partie de cours sur la stabilité des solutions d'une équation différentielle, ce qui nous permettra ensuite d'étudier les états d'équilibre de modèles compartimentaux pour des épidémies ordinaires. Ensuite, nous nous intéressons également aux apocalypses zombies et adaptons les modèles à compartiments pour essayer de modéliser les chances de survie de l'humanité. Enfin, nous discutons des limites des modèles à compartiments.

Table des matières

1	Introduction	1
2	Stabilité d'une solution	3
2.1	Définitions	3
2.2	Cas d'un système linéaire à coefficients constants	4
2.3	Linéarisation des systèmes non-linéaires	6
3	Modèles compartimentaux ordinaires	7
3.1	Susceptibles, Infectés, Retirés	7
3.1.1	Modèle, schéma et système	7
3.1.2	Système différentiel	10
3.1.3	Étude des équilibres	11
3.1.4	Simulations numériques	11
3.2	Susceptibles, Infectés, Retirés avec démographie	15
3.2.1	Modèle, schéma et système	15
3.2.2	Système différentiel	15
3.2.3	Études des équilibres	16
3.2.4	Simulations numériques	17
3.3	Susceptibles, Exposés, Infectés, Retirés avec démographie	19
3.3.1	Modèle, schéma et système	19
3.3.2	Système différentiel	20
3.3.3	Étude des équilibres	21
3.3.4	Simulations numériques	22
4	Modèles compartimentaux et épidémie de zombies	23
4.1	Qu'est-ce qu'une épidémie de zombie ?	23
4.2	Susceptible, Zombies, Retirés	24
4.2.1	Modèle, schéma et système	24
4.2.2	Système différentiel	25
4.2.3	Étude des équilibres	25
4.2.4	Simulations numériques	26
5	Critique des modèles SIR et SEIR	26
5.1	La difficulté de paramétrage	26
5.2	Hypothèses sur les compartiments et les relations	27
6	Conclusion	28
7	Annexe	29

2 Stabilité d'une solution

2.1 Définitions

Pour l'ensemble des modèles que nous allons aborder dans ce document, nous allons étudier la stabilité de leurs états d'équilibre. Pour cela, nous commençons dans cette première partie par définir clairement la stabilité (et l'instabilité) d'un état d'équilibre, ainsi que les conditions qui permettent de déterminer dans lequel des cas se trouve un état donné. Cette partie se base sur le chapitre 6 du livre [Berthelin(2017)], sur le chapitre X du livre [Demailly(2012)] et sur le cours de [Chill(2007)].

Tout d'abord, commençons par un exemple simple pour mieux comprendre : le pendule à tige rigide. Nous avons une masse reliée à un point fixe par une tige rigide. Ce système possède deux états d'équilibre : la position verticale orientée vers le haut (la masse est au-dessus du point fixe) et la position verticale orientée vers le bas. Nous allons étudier la réaction du système en cas de légère perturbation.

Équilibre vertical masse vers le bas :

Lorsqu'on écarte légèrement le pendule de sa position initiale, la pesanteur tend à ramener la masse vers sa position initiale. Le pendule oscille alors autour de position d'équilibre avec une amplitude ne dépassant pas l'écart initial (par conservation de l'énergie mécanique). On parle alors de stabilité. De plus, en cas de frottements, après un temps suffisamment long, le système retournera dans l'état d'équilibre vertical masse vers le bas. On parle de stabilité locale asymptotique.

Équilibre vertical masse vers le haut :

Dans ce cas, avec ou sans frottements, lorsque le pendule est légèrement éloigné de sa position initiale, il s'éloigne de celle-ci et ne l'atteint plus, même après un temps infiniment long. On parle d'instabilité.

Maintenant définissons mathématiquement ces différentes notions. On se place dans le cadre suivant :

Soient $\mathbb{K} = \mathbb{R}$ ou $\mathbb{C}$, Ω un ouvert de $\mathbb{K}^N$ et $f : \mathbb{R} \times \Omega \longrightarrow \mathbb{K}^N$ continue et localement lipschitzienne par rapport à la seconde variable.

On s'intéresse à l'équation différentielle suivante :

$$y' = f(t, y) \tag{1}$$

avec condition initiale $y(t_0) = y_0$. L'existence d'une solution maximale de (1) est assurée par le théorème de Cauchy-Lipschitz local et on suppose que cette solution existe sur $[t_0; \infty[$. On note de $y_{t_0, z}$ la solution maximale de (1) telle que $y_{t_0, z}(t_0) = z$.

Définition : (Stabilité)

La solution y_{t_0, y_0} est stable (à droite) si :

- (1) Il existe $\alpha > 0$ tel que, pour tout $y_1 \in \Omega$ tel que $\|y_1 - y_0\| \leq \alpha$, la fonction $y_{t_0, y_1}(t)$ est définie sur $[t_0; \infty[$.
- (2) Pour tout $\epsilon > 0$, il existe $\eta > 0$ tel que, pour tout $y_1 \in \Omega$ tel que $\|y_1 - y_0\| \leq \eta$, alors pour tout $t \geq t_0$, $\|y_{t_0, y_1}(t) - y_{t_0, y_0}(t)\| \leq \epsilon$.

Définition : (Attractivité)

La solution y_{t_0, y_0} est attractive (à droite) s'il existe $\delta > 0$ tel que pour tout $y_1 \in \Omega$ tel que $\|y_1 - y_0\| \leq \delta$ on a $y_{t_0, y_1}(t) - y_{t_0, y_0}(t) \xrightarrow[t \rightarrow \infty]{} 0$.

Définition : (Stabilité asymptotique)

Une solution y_{t_0, y_0} est dite asymptotiquement stable (à droite) si elle est stable (à droite) et attractive (à droite).

Remarque : On peut de même définir la stabilité, l'attractivité et la stabilité asymptotique à gauche ($t \leq t_0$). Mais en pratique, on souhaite savoir s'il se passera dans le futur ($t \geq t_0$) plutôt que dans le passé ($t \leq t_0$). Lorsque l'on parle de stabilité sans préciser à gauche ou à droite, il est sous-entendu qu'il s'agit de la stabilité à droite.

Définition : (Point singulier)

Étant donnée une équation différentielle autonome $y' = f(y)$, on appelle point singulier tout zéro de la fonction f .

2.2 Cas d'un système linéaire à coefficients constants

Nous étudions ici un cas simple, à savoir le cas d'un système linéaire à coefficients constants sans second membre

$$Y' = AY, \quad Y = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}, \quad A = \begin{pmatrix} a_{11} & \dots & a_{1m} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mm} \end{pmatrix}$$

où les coefficients $a_{i,j}$ sont dans $\mathbb{C}$, le cas réel pouvant être vu comme un cas particulier du cas complexe. La solution du problème de Cauchy de condition initiale $Y(t_0) = Z$ est donnée par $Y_{t_0, Z}(t) = e^{(t-t_0)A}Z$. On a donc :

$$Y_{t_0, Z}(t) - Y_{t_0, Y_0}(t) = e^{(t-t_0)A}(Z - Y_0)$$

et la stabilité est donc liée au comportement de $e^{(t-t_0)A}$ lorsque t tend vers $+\infty$. On distingue alors plusieurs cas.

- $m = 1$, $A = (a)$, alors :

$$|e^{(t-t_0)a}| = e^{(t-t_0)\Re(a)}.$$

Les solutions sont stables si et seulement si cette quantité reste bornée quand t tend vers $+\infty$, c'est-à-dire si $\Re(a) \leq 0$. De même, les solutions sont asymptotiquement stables si et seulement si $\Re(a) < 0$.

- $m \in \mathbb{N}^*$.

- Si A est diagonalisable, on étudie la matrice diagonale équivalente :

$$\tilde{A} = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_m \end{pmatrix}$$

où $\lambda_1, \dots, \lambda_m$ désignent les valeurs propres de A .

Le système est alors stable si chacun des coefficients diagonaux de $e^{t\tilde{A}}$ reste borné, c'est-à-dire si et seulement si $\forall j \in \llbracket 1; m \rrbracket, \Re(\lambda_j) \leq 0$, et asymptotiquement stable si et seulement si $\forall j \in \llbracket 1; m \rrbracket, \Re(\lambda_j) < 0$.

- si A n'est pas diagonalisable, on étudie chacun des blocs J_{λ_i} qui apparaît dans la forme réduite de Jordan de A qui sont de la forme :

$$J_{\lambda_i} = \begin{pmatrix} \lambda_i & & * \\ & \ddots & \\ 0 & & \lambda_i \end{pmatrix} = \lambda_i I + N$$

où N est une matrice triangulaire strictement supérieure (donc nilpotente) non nulle. Alors :

$$\begin{aligned} e^{(t-t_0)J_{\lambda_i}} &= e^{(t-t_0)\lambda_i I} e^{(t-t_0)N} \\ &= e^{(t-t_0)\lambda_i} \sum_{k=0}^{m-1} \frac{(t-t_0)^k}{k!} N^k, \end{aligned}$$

Donc les coefficients de $e^{(t-t_0)A}$ sont des combinaisons linéaires de produit de $e^{(t-t_0)\lambda_i}$ par des polynômes de degré au plus $m-1$ non constants (car $N \neq 0$). Si $\Re(\lambda_i) < 0$, les coefficients tendent vers 0, et si $\Re(\lambda_i) > 0$ les coefficients divergent lorsque t tend vers $+\infty$, car la croissance de l'exponentielle l'emporte sur celle des polynômes. Enfin, si $\Re(\lambda_i) = 0$, les coefficients divergent à cause des polynômes et ainsi $e^{(t-t_0)A}$ est non borné.

La formule explicite de $e^{(t-t_0)J_{\lambda_i}}$ nous permet de plus d'obtenir des constantes réelles $M, \omega > 0$ tels que :

$$\|e^{(t-t_0)J_{\lambda_i}}\| \leq M e^{-\omega(t-t_0)}, \quad t \geq 0.$$

où $\omega \in]0, -\lambda[$.

Ainsi, on obtient des constantes $M, \omega > 0$ tels que pour tout $Z \in \mathbb{K}^N$:

$$\|e^{(t-t_0)A} Z\| \leq M e^{-\omega(t-t_0)} \|Z\|, \quad t \geq 0.$$

On dit que la solution $Y_{t_0, Z}$ est exponentiellement stable.

En résumé, on peut énoncer :

Théorème - Soient $\lambda_1, \dots, \lambda_r$ les valeurs propres complexes de la matrice A . Alors les solutions du système linéaire $Y' = AY$ sont :

- stables si et seulement si, $\forall j \in \llbracket 1; r \rrbracket, \Re(\lambda_j) < 0$ ou bien $\Re(\lambda_j) = 0$ et le bloc correspondant est diagonalisable.
- asymptotiquement stables si et seulement si $\Re(\lambda_j) < 0$ pour tout $j = 1, \dots, r$.
- asymptotiquement stables si et seulement si elles sont exponentiellement stables.

2.3 Linéarisation des systèmes non-linéaires

On s'intéresse à la stabilité des systèmes non-linéaires, on étudie l'équation différentielle autonome suivante, notée (E) :

$$y'(t) = f(y(t))$$

où f est une fonction continue sur Ω un ouvert de $\mathbb{K}^N$. On énonce le théorème suivant, dit théorème de linéarisation de Lyapunov, qui est une conséquence du théorème de stabilité dans le cas linéaire et du Lemme de Grönwall, il fournit une condition suffisante sur la stabilité asymptotique des points singuliers d'une équation différentielle :

Théorème (Lyapunov) - Soient $t_0 \in \mathbb{R}$ et $y_0 \in \Omega$ un point singulier de (E). On suppose que f est C^1 au voisinage de y_0 et on suppose de plus que les valeurs propres de la dérivée $f'(y_0) \in \mathbb{K}^{N \times N}$ (ou de façon équivalente de la matrice jacobienne de f évaluée en y_0) sont toutes de partie réelle strictement négative. Alors la solution du problème de Cauchy y_{t_0, y_0} est asymptotiquement stable.

Démonstration [Chill(2007)] Quitte à remplacer la fonction f par la fonction translatée $f(\cdot - y_0)$ et la solution y par $y - y_0$, nous pouvons supposer que $y_0 = 0$. On écrit alors le développement de Taylor à l'ordre 1 de f en 0, on pose $A := f'(0)$, on obtient donc dans un voisinage de 0 :

$$\begin{aligned} f(y) &= f(0) + f'(0)y + r(y) \\ &= Ay + r(y) \end{aligned}$$

où r est le reste à l'ordre 1 du développement, en particulier r est continue et vérifie : $\frac{\|r(y)\|}{\|y\|} \xrightarrow{y \rightarrow 0} 0$. L'équation différentielle devient :

$$y'(t) = Ay(t) + r(y(t)).$$

D'après les hypothèses sur A et le premier théorème de stabilité dans le cas linéaire, les solutions de $y'(t) = Ay(t)$ sont exponentiellement stables, il existe donc $M, \omega > 0$ tels que pour tout $y_1 \in \mathbb{K}^N$,

$$\|e^{(t-t_0)A}y_1\| \leq Me^{-\omega(t-t_0)}\|y_1\|, \quad t \geq 0.$$

Puis par hypothèse sur la fonction r , il existe $\delta > 0$ tel que pour tout $x \in \mathbb{K}^N$ vérifiant $\|x\| \leq \delta$ alors $\|r(x)\| \leq \frac{\omega}{2M}\|x\|$.

Soit $y_1 \in \mathbb{K}^N$ tel que $\|y_1\| \leq \frac{\delta}{2M}$, et soit y_{t_0, y_1} une solution maximale de (E) sur un intervalle $[0, T[$ (existe d'après le théorème de Cauchy-Lipschitz local, car f est C^1 et donc localement lipschitzienne).

De plus, la solution s'écrit sous la forme :

$$y_{t_0, y_1}(t) = e^{(t-t_0)A}y_1 + \int_{t_0}^t e^{(t-s)A}r(y_{t_0, y_1}(s)) \, ds, \quad t \in [0, T[.$$

Puis par inégalité triangulaire, on obtient :

$$\|y_{t_0, y_1}(t)\| \leq M e^{-\omega(t-t_0)} \|y_1\| + \int_{t_0}^t M e^{-\omega(t-s)} \frac{\omega}{2M} \|y_{t_0, y_1}(s)\| ds,$$

soit encore :

$$e^{\omega t} \|y_{t_0, y_1}(t)\| \leq M e^{\omega t_0} \|y_1\| + \int_{t_0}^t \frac{\omega}{2} e^{\omega s} \|y_{t_0, y_1}(s)\| ds.$$

Puis, le Lemme de Grönwall implique :

$$\begin{aligned} e^{\omega t} \|y_{t_0, y_1}(t)\| &\leq M e^{\omega t_0} \|y_1\| e^{\int_{t_0}^t \frac{\omega}{2} ds} \\ &\leq M e^{\omega t_0} \|y_1\| e^{\frac{\omega}{2}(t-t_0)}. \end{aligned}$$

Finalement :

$$\|y_{t_0, y_1}(t)\| \leq M \|y_1\| e^{-\frac{\omega}{2}(t-t_0)}, \quad t \in [0, T[$$

Ainsi, par le choix de y_1 , cette inégalité implique que y_{t_0, y_1} est bornée par $\frac{\delta}{2}$, donc par le théorème des bouts, la solution existe pour tout $t \geq 0$. Finalement, la dernière inégalité est vraie pour tout y_1 dans un voisinage de 0, la solution y_{t_0, y_0} est donc asymptotiquement stable.

Remarque : pour étudier la stabilité d'un système différentiel, il suffira d'étudier le signe des valeurs propres de la jacobienne évaluée au point singulier du système.

3 Modèles compartimentaux ordinaires

Dans un premier temps, nous allons étudier les modèles à compartiments appliqués à des épidémies ordinaires. Nous verrons trois types de modèles prenant en compte divers aspects d'une épidémie et d'une population comme la démographie ou le temps d'exposition à l'infection.

Pour chacun d'entre eux, nous commencerons par poser les variables de notre modèle : compartiments et relations entre compartiments, puis étudierons les états d'équilibre du système différentiel associé et nous compléterons notre analyse par des simulations numériques.

3.1 Susceptibles, Infectés, Retirés

3.1.1 Modèle, schéma et système

Le modèle SIR est le plus commun et l'un des plus classiques pour la modélisation par des compartiments. Bien que simple, il permet de bien comprendre le fonctionnement de ce genre de modèles.

Le modèle SIR est composé de trois compartiments :

- Les **Susceptibles**, dont la densité à l'instant t est noté $S(t)$. Ce sont tous les individus de la population qui n'ont pas été en contact avec l'agent infectieux à l'instant t .
- les **Infectés**, dont la densité est notée $I(t)$ à l'instant t . Ce sont les individus porteurs de l'agent infectieux et capables de le transmettre au reste de la population. On fait de plus les hypothèses suivantes :
 - Tous les infectés transmettent la maladie.
 - Le taux de transmission est identique pour tous les infectés.
 - Un individu qui quitte ce compartiment ne peut plus participer à la dynamique épidémique.
- Les **Retirés**, dont on note la densité $R(t)$ à l'instant t . Ce sont les individus qui ont été infectés et qui ne peuvent plus transmettre l'agent infectieux. Cette catégorie comprend les personnes qui ont guéri et acquis l'immunité à la maladie, les personnes en quarantaine ou isolement (parfait) qui ne peuvent plus infecter la population et enfin les personnes décédées.

Nous allons également faire plusieurs hypothèses sur la population :

On travaillera dans un premier temps sur une épidémie de courte durée, c'est-à-dire suffisamment rapide pour pouvoir négliger les fluctuations de démographie comme la natalité, la migration ou la mortalité naturelle de la population. On peut donc faire l'hypothèse que la population totale est constante. Cette hypothèse sera partiellement prise en compte dans les modèles suivants. Nous travaillons également sur la densité de population totale pour éviter d'introduire le nombre total d'individus.

L'hypothèse d'une population constante se traduit mathématiquement par : $\frac{d}{dt}(S + I + R) = 0$ et comme nous travaillons sur la densité de population totale, nous avons $S(0) + I(0) + R(0) = 1$. Ce qui nous donne :

$$\forall t \in \mathbb{R}^+, S(t) + I(t) + R(t) = 1$$

Nous faisons également l'hypothèse que les différentes catégories de population sont réparties de façon homogène dans l'espace, ainsi les variables S , I et R ne dépendent que du temps t . Dans les faits, cette hypothèse peut être vérifiée à l'échelle d'une ville, mais est irréaliste à l'échelle d'une région ou d'un pays par exemple.

Enfin, nous faisons l'hypothèse d'un mélange parfait entre les différentes catégories de population, chaque individu a la même probabilité d'interagir avec n'importe quel autre, afin de pouvoir modéliser les interactions par une **loi d'action de masse**.

Le modèle SIR est composé de deux relations :

- **L'infection d'un susceptible par un infecté.** On suppose que cette infection dépend d'un paramètre $\beta \in \mathbb{R}_+^*$. Il représente le taux de transmission du virus. Ce taux de transmission comprend deux aspects de natures différentes : le premier est social, il comprend le taux r de rencontre entre deux individus, le second est biologique, il comprend la probabilité c qu'a le virus de se transmettre lors d'une rencontre. Autrement dit : $\beta = rc$. Par exemple : une mesure de confinement vise à diminuer le taux de rencontre r et un virus très contagieux aura un paramètre c élevé.
- **La guérison d'un infecté.** On suppose qu'il dépend d'un paramètre $\gamma \in \mathbb{R}_+^*$. On peut voir γ comme l'inverse de la durée moyenne où un individu reste contagieux avant de devenir retiré. Cette durée dépend des caractéristiques de la maladie et de comment les infectés sont détectés et isolés.

Ainsi, on peut schématiser le modèle SIR comme suivant :



Pour notre modélisation mathématique, nous cherchons à exprimer l'évolution des différentes populations des compartiments. On se donne à un instant t les densités de population et on souhaite connaître les densités de populations à un instant ultérieur $t+dt$.

Selon les relations que nous avons posées précédemment, nous obtenons le système suivant à l'instant $t+dt$:

$$\begin{cases} S(t+dt) = S(t) - \beta S(t)I(t)dt & \textbf{(1)} \\ I(t+dt) = I(t) + \beta S(t)I(t)dt - \gamma I(t)dt & \textbf{(2)} \\ R(t+dt) = R(t) + \gamma I(t)dt & \textbf{(3)} \end{cases}$$

Donnons un sens à chacun des termes qui apparaissent.

(1) La population susceptible à l'instant $t+dt$ comprend la population susceptible déjà présente (terme $S(t)$) auquel on soustrait le terme $\beta S(t)I(t)dt$ qui correspond à la population qui devient infectieuse entre les instants t et $t+dt$.

Pour obtenir ce terme, on fait l'hypothèse que la transmission de l'agent pathogène est proportionnelle à la durée dt , qu'elle dépend du taux de transmission β et suit une loi d'attraction de masse. La population infectée durant l'intervalle dt est proportionnelle au produit de la proportion de susceptibles dans la population par la force d'infection $F(I, t)$. On suppose que $F(I, t)$ est indépendante du temps et proportionnelle à la proportion d'infectés dans la population.

(2) On raisonne de la même façon pour la population infectée. Sa densité à l'instant $t+dt$ comprend la densité de population infectée déjà présente à l'instant t , auquel

on ajoute la population qui est infectée entre les instants t et $t+dt$, c'est le terme $\beta S(t)I(t)dt$. Enfin, on lui soustrait la population qui cesse d'être contagieuse entre les instants t et $t+dt$, c'est le terme $-\gamma I(t)$.

(3) Enfin, la population retirée correspond au reste de la population. $R = 1 - S - I$.

Remarque : une première observation importante que l'on peut faire c'est qu'à tout instant nous avons la relation suivante :

$$\forall t \in \mathbb{R}^+, S(t+dt) + I(t+dt) + R(t+dt) = S(t) + I(t) + R(t)$$

La population ne varie pas au cours du temps, ce qui traduit bien notre hypothèse de population constante dans notre étude.

3.1.2 Système différentiel

On cherche maintenant à mettre les relations que l'on a obtenues sous une forme plus satisfaisante. Le système peut se réécrire :

$$\begin{cases} \frac{S(t+dt) - S(t)}{dt} = -\beta S(t)I(t) \\ \frac{I(t+dt) - I(t)}{dt} = +\beta S(t)I(t) - \gamma I(t) \\ \frac{R(t+dt) - R(t)}{dt} = +\gamma I(t) \end{cases}$$

On peut maintenant faire tendre le paramètre dt vers 0. On obtient alors le **modèle SIR** :

$$\begin{cases} \frac{dS}{dt} = -\beta SI \\ \frac{dI}{dt} = +\beta SI - \gamma I \\ \frac{dR}{dt} = +\gamma I \end{cases} \quad \text{avec } \begin{matrix} S(0) = S_0, & I(0) = I_0 \text{ et } R(0) = 0 \end{matrix}$$

Remarque : on peut prendre $R(0) = 0$ au démarrage de l'épidémie, puisque la population retirée n'interagit pas avec les autres compartiments.

Remarque : ce modèle se nomme également **Modèle de Kermack et McKendrick**.

On s'aperçoit que les deux premières lignes ne dépendent pas de la troisième puisque $R(t)$ n'y figure pas et que l'on peut déduire $R(t)$ grâce à la relation $S(t) + I(t) + R(t) = 1$. On peut donc l'omettre et se ramener au système suivant, aussi appelé **Modèle SIR simplifié** :

$$\begin{cases} \frac{dS}{dt} = -\beta SI \\ \frac{dI}{dt} = +\beta SI - \gamma I \end{cases}$$

3.1.3 Étude des équilibres

Dans cette section, nous allons nous intéresser aux états où le système cesse d'évoluer, les états d'équilibre. Pour cela, étudions la jacobienne associée au système différentiel que nous avons obtenu précédemment et plus particulièrement à ses valeurs propres.

$$\begin{cases} \frac{dS}{dt} = -\beta SI \\ \frac{dI}{dt} = \beta SI - \gamma I = \gamma \left(\frac{\beta}{\gamma} S - 1 \right) I \end{cases}$$

On effectue alors le changement de variable $\tau = \gamma t$ et on introduit le facteur $R_0 = \frac{\beta}{\gamma}$, le système se réécrit alors :

$$\begin{cases} \frac{dS}{d\tau} = -R_0 SI \\ \frac{dI}{d\tau} = (R_0 S - 1) I \end{cases}$$

La jacobienne associée à ce système vaut alors :

$$J(S, I) = \begin{bmatrix} -R_0 I & -R_0 S \\ R_0 I & R_0 S - 1 \end{bmatrix}$$

Les points d'équilibre de ce système ou points singuliers, sont donc atteints lorsque la population d'infectés est nulle :

$$(S^*, I^*) = (\alpha, 0), \quad \alpha \in [0; 1]$$

$$J(S^*, I^*) = \begin{bmatrix} 0 & -R_0 \alpha \\ 0 & R_0 \alpha - 1 \end{bmatrix}$$

Les valeurs propres de la jacobienne sont alors :

$$(\lambda_1, \lambda_2) = (0, R_0 \alpha - 1)$$

Si R_0 est strictement inférieure à $\frac{1}{\alpha}$ alors la valeur propre λ_2 est négative, une condition nécessaire (mais pas suffisante) pour obtenir la stabilité du système. On observe que si $R_0 < 1$ alors $\frac{dI}{dt} < 0$, la maladie ne peut pas s'installer. Cependant, l'autre valeur propre λ_1 étant nulle, l'équilibre ne peut pas être asymptotiquement stable.

3.1.4 Simulations numériques

Dans cette partie, nous allons nous appuyer sur la simulation numérique afin de mieux visualiser l'impact des conditions initiales et des choix de variables γ et β sur le pic de l'épidémie et sa durée totale. Pour cela, nous avons codé en Python plusieurs algorithmes permettant de reproduire l'évolution des compartiments au fil de l'épidémie. On peut retrouver le code en annexe du rapport 7.

Tout d'abord, nous nous intéressons à l'impact du paramètre β . On obtient alors la figure 1.




FIGURE 1 – Modélisation SIR pour $\gamma = 0.1$ et $\beta = 0.3$ puis 0.5

On voit que le fait d'augmenter β réduit la durée de l'épidémie, mais la rend plus virulente. La quasi-totalité de la population aura été infectée pour $\beta = 0.5$ alors qu'environ un dixième de la population n'aura pas été infectée pour $\beta = 0.3$. On voit également que pour un β plus élevé, la part de la population infectée au même instant est plus élevée : 0.3 contre 0.5, c'est **le pic de l'épidémie**. Ainsi, on comprend l'intérêt de vouloir réduire la vitesse de transmission de l'épidémie pour éviter d'avoir trop de malades en même temps (notamment par rapport à un nombre limité de lits d'hôpitaux...).

Durant l'épidémie de covid, un des moyens de réduire cette vitesse de transmission a été l'instauration de confinements successifs. Nous nous intéressons donc aux effets de cette mesure et notamment au moment optimal où l'instaurer. On obtient la figure 2.




FIGURE 2 – Modélisation SIR pour $\gamma = 0.1, \beta = 0.35$ hors confinement et $\beta = 0.2$ en confinement

On observe que l'instauration d'un confinement trop tardif ($t_1 = 32$) n'a pas d'effet sur le pic de l'épidémie. Mais on remarque que le fait d'instaurer un confinement trop tôt n'est pas efficace non plus ($t_1 = 7, 12$). En effet, il y a un rebond de l'épidémie autour

du 50ème jour avec des pics assez proche de celui sans confinement. Ainsi, il semblerait optimal, dans notre cas, d'instaurer un confinement à $t_1 = 17$ ou 22 pour obtenir des pics en dessous des 25%.

Une autre façon de réduire le pic d'une épidémie est d'agir sur ce paramètre, notamment au travers de tests de dépistage qui permettent aux individus contagieux repérés de s'isoler et de ne plus contaminer personne (dans l'idéal). Pour cela, nous regardons également l'effet du paramètre γ sur notre modélisation, en prenant différentes valeurs. On obtient la figure 3.

Nous pouvons voir que l'augmentation du facteur γ (*ie.* diminution de la durée durant




FIGURE 3 – Modélisation SIR pour $\beta = 0.3$ - Influence du paramètre γ

laquelle un infecté peut contaminer un individu susceptible), permet d'aplatir le pic de l'épidémie sans forcément allonger sa durée comme le faisait la diminution du facteur β .

Nous souhaitons ensuite illustrer des cas avec le même R_0 mais avec des valeurs de β et γ différents. On obtient la figure 4.

On observe que le pic de l'épidémie atteint la même intensité pour chaque couple, mais qu'il ne se produit pas au même moment. Plus β est grand, plus le pic arrive tôt et plus il est court.




FIGURE 4 – Modélisation SIR pour différents couples γ et β avec $R_0 = \frac{5}{3}$

Enfin, nous voulons modéliser l'influence de la répartition initiale de chacun des compartiments sur l'évolution de l'épidémie. Pour cela, nous utilisons un plan de phase. On obtient alors la figure 5. Les informations qui nous intéressent sont sur la diagonale inférieure puisque dans notre cas $S(0) + I(0) \leq 1$.




FIGURE 5 – Plan de phase pour $\beta = 0.5$ et $\gamma = 0.3$

On retrouve bien les résultats de notre étude théorique, le système fini toujours par converger vers une forme $(S^*, I^*) = (\alpha, 0)$.

3.2 Susceptibles, Infectés, Retirés avec démographie


3.2.1 Modèle, schéma et système

Nous cherchons maintenant à modéliser une épidémie d'une plus grande durée, nous allons donc prendre en compte la natalité et la mortalité dans la population.

Le modèle **SIR démographique** reprend les compartiments Susceptibles, Infectés et Retirés et nous faisons les mêmes hypothèses sur la population totale que pour le modèle SIR simple. La différence entre le modèle SIR normal et démographique se fait au niveau des relations. On retrouve l'infection d'un susceptible par un infecté dépendant de $\beta \in \mathbb{R}_+^*$ et la guérison d'un infecté qui dépend d'un paramètre $\gamma \in \mathbb{R}_+^*$. Mais nous ajoutons deux nouvelles relations :

- **La naissance de nouveaux individus**, que l'on représente par un facteur $\mu \in \mathbb{R}_+^*$ compris entre 0 et 1. On suppose que les nouveaux individus ne sont pas infectés ni retirés (ce qui n'est pas le cas du VIH par exemple), on les ajoute donc au compartiment des susceptibles.
- **Le décès des individus déjà présents**. Puisqu'on a supposé que la mortalité était égale à la natalité, elle dépend également du facteur μ . De plus, on fait la supposition que la mortalité est la même pour chacun des compartiments.

On peut schématiser le modèle comme suit :



Pour notre modélisation mathématique, nous cherchons à nouveau à exprimer l'évolution de chacun des compartiments d'un instant t à instant $t+dt$ avec dt suffisamment petit pour que $S(t)$, $I(t)$ et $R(t)$ soient constants. On obtient alors le système suivant à l'instant $t+dt$ à partir des relations que nous avons posées.

$$\begin{cases} S(t+dt) = S(t) - \beta S(t)I(t)dt + \mu dt - \mu S(t)dt \\ I(t+dt) = I(t) + \beta S(t)I(t)dt - \gamma I(t)dt - \mu I(t)dt \\ R(t+dt) = R(t) + \gamma I(t)dt - \mu R(t)dt \end{cases}$$

3.2.2 Système différentiel

On peut maintenant faire tendre le paramètre dt vers 0. On obtient alors le **modèle SIR démographique** :

$$\begin{cases} \frac{dS}{dt} = -\beta SI - \mu S + \mu \\ \frac{dI}{dt} = (\beta S - \gamma - \mu)I \\ \frac{dR}{dt} = \gamma I - \mu R \end{cases} \quad \text{avec } \begin{matrix} S(0) = S_0, & I(0) = \\ I_0 \text{ et } R(0) = 0 \end{matrix}$$

Comme pour le modèle SIR normal, on peut retrouver la troisième ligne à partir des deux premières. Le système peut se réécrire :

$$\begin{cases} \frac{dS}{dt} = -\beta SI + \mu(1 - S) \\ \frac{dI}{dt} = (\gamma + \mu)\left(\frac{\beta}{\gamma + \mu}S - 1\right)I \end{cases}$$

Pour y voir plus clair, on pose le changement de variable suivant : $\tau = t(\gamma + \mu)$

$$\begin{cases} \frac{dS}{d\tau} = \frac{1}{\gamma + \mu}(-\beta SI + \mu(1 - S)) \\ \frac{dI}{d\tau} = \left(\frac{\beta}{\gamma + \mu}S - 1\right)I \end{cases}$$

On pose $R_0 = \frac{\beta}{\gamma + \mu}$ dans les égalités. Finalement, on obtient :

$$\begin{cases} \frac{dS}{d\tau} = -R_0 SI + \frac{\mu}{\gamma + \mu}(1 - S) \\ \frac{dI}{d\tau} = (R_0 S - 1)I \end{cases}$$

3.2.3 Études des équilibres

Maintenant, étudions les états d'équilibre du système. Pour cela, nous allons regarder la jacobienne associée :

$$J(S, I) = \begin{bmatrix} -R_0 I - \frac{\mu}{\mu + \gamma} & -R_0 S \\ R_0 I & R_0(S - 1) \end{bmatrix}$$

Dans notre système différentiel, nous avons un point singulier dans la deuxième ligne : $I(R_0 S - 1) = 0$. Étudions la jacobienne selon les deux possibilités : $I = 0$ et $R_0 S - 1 = 0$.

I. Cas $I = 0$

Dans ce cas, on a $R = 0$ et $S = 1$ par l'action de la natalité et la mortalité, l'ensemble de la population de retirés a disparu. On prend donc $(S^*, I^*) = (1, 0)$

$$J(S^*, I^*) = \begin{bmatrix} -\frac{\mu}{\mu + \gamma} & -R_0 \\ 0 & R_0 - 1 \end{bmatrix}$$

Par le calcul du déterminant et de la trace, on trouve que les valeurs propres sont :

$$(\lambda_1, \lambda_2) = \left(-\frac{\mu}{\mu+\gamma}, R_0 - 1 \right)$$

La première valeur propre est toujours négative, mais le signe de la deuxième dépend de R_0 . On a une stabilité asymptotique si et seulement si $R_0 < 1$.

II. Cas $I \neq 0$ et $SR_0 - 1 = 0$

On a alors $S^* = \frac{1}{R_0}$ et alors d'après la première équation, on obtient $I^* = \frac{\mu}{\mu+\gamma}(1 - \frac{1}{R_0})$.

On prend donc $(S^*, I^*) = (\frac{1}{R_0}, \frac{\mu}{\mu+\gamma}(1 - \frac{1}{R_0}))$ et la jacobienne associée devient :

$$J(S^*, I^*) = \begin{bmatrix} -R_0 \frac{\mu}{\mu+\gamma} & -1 \\ \frac{\mu}{\mu+\gamma}(R_0 - 1) & 0 \end{bmatrix}$$

On a donc à partir de la trace et du déterminant de la jacobienne :

$$\begin{aligned} \lambda_1 + \lambda_2 &= -R_0 \frac{\mu}{\mu+\gamma} < 0 \\ \lambda_1 \lambda_2 &= \frac{\mu}{\mu+\gamma}(R_0 - 1) \end{aligned}$$

On a donc, à nouveau, deux possibilités :

Si $\lambda_1 \lambda_2 > 0 \Leftrightarrow R_0 > 1$ alors les valeurs propres sont de même signe. Or, leur somme est négative, les deux valeurs propres sont donc négatives. On a alors un état d'équilibre asymptotiquement stable.

Si $\lambda_1 \lambda_2 < 0 \Leftrightarrow R_0 < 1$ alors $\lambda_1 < 0$ et $\lambda_2 > 0$ (ou inversement), on a alors un état d'équilibre instable.

Donc, on a un état d'équilibre asymptotiquement stable si et seulement si $R_0 > 1$.

3.2.4 Simulations numériques

Illustrons notre analyse théorique par des simulations numériques afin de mieux comprendre les différents états d'équilibre possibles. Le code pour les différents algorithmes se trouve en annexe 7.

Tout d'abord, regardons le profil d'une épidémie pour un $R_0 > 1$. Nous obtenons la figure 6.

On observe la présence de plusieurs pics épidémiques : un premier important vers 50 jours, puis un deuxième de plus faible amplitude vers 200 jours et enfin un bien plus faible vers 350 jours. On voit bien que la prise en compte de la démographie entraîne un véritable changement dans la modélisation. Enfin, le système finit par se stabiliser vers 400 jours, mais contrairement au modèle SIR de base, où la part d'infectés finit par être nulle, on obtient un équilibre avec une part d'infectés constante.

Ainsi, nous souhaitons étudier le plan de phase du modèle SIR démographique en fonction de la valeur de R_0 car nous avons vu dans notre étude théorique que l'on pouvait




FIGURE 6 – Simulation SIR démographique pour $\gamma = 0.2, \beta = 0.4$ et $\mu = 0.0009$

différencier deux cas de stabilité asymptotique : $R_0 > 1$ et $R_0 < 1$. Dans ce deuxième cas, l'épidémie n'a pas lieu, nous ne l'illustrons pas. Pour $R_0 > 1$ nous obtenons la figure 7.




FIGURE 7 – Plan de phase avec $R_0 < 1$

Lorsque $R_0 > 1$, on est dans le cas d'un équilibre sous la forme $(S^*, I^*) = (\frac{1}{R_0}, \frac{\mu}{\mu+\gamma}(1 - \frac{1}{R_0}))$. Nous avons vu dans la partie théorique que cet état d'équilibre est alors attractif, ce qui se traduit par le fait que toutes les flèches tournent et terminent autour de ce point.

3.3 Susceptibles, Exposés, Infectés, Retirés avec démographie

Nous nous intéressons ensuite à un modèle un peu plus élaboré que le modèle SIR. Nous souhaitons prendre en compte le temps d'incubation au cours duquel un individu récemment contaminé n'est pas encore contagieux. Nous gardons également la notion de démographie. Nous allons voir comment l'ajout de ce nouveau compartiment va affecter la modélisation et les états d'équilibre.

3.3.1 Modèle, schéma et système


Pour le modèle **SEIR avec démographie**, nous reprenons les compartiments de susceptibles, infectés et retirés et nous ajoutons le compartiment des **exposés** : les individus qui ont été récemment contaminés par une personne infectée, mais qui ne peuvent pas encore transmettre l'agent infectieux.

Nous faisons les mêmes hypothèses sur la population totale que pour le modèle SIR simple. On suppose que les variables S, E, I et R ne dépendent que du temps, on fait l'hypothèse d'un mélange parfait entre les différentes catégories de population pour modéliser les interactions par une loi d'action de masse et on suppose que la population est constante.

Les relations de guérison et de démographie sont les mêmes que pour le modèle SIR, mais l'ajout du compartiment des exposés modifie les deux relations reliées à l'infection :

- **L'infection d'un susceptible par un infecté**, qui dépend toujours du paramètre $\beta \in \mathbb{R}_+^*$ qui représente la vitesse de transmission du virus. Cependant, dans ce nouveau modèle, cette relation se fait entre le compartiment des susceptibles vers celui des exposés.
- **La fin de la phase d'incubation** qui dépend d'un paramètre $\alpha \in \mathbb{R}_+^*$. Ce paramètre correspond à l'inverse de la durée après laquelle un individu exposé devient capable de transmettre l'agent infectieux et passe donc dans le compartiment des infectés.

On peut alors représenter le modèle sous la forme de schéma :



À nouveau, on souhaite savoir comment évoluent les compartiments sur une courte période dt . On obtient le système suivant au temps $t+dt$:

$$\begin{cases} S(t+dt) = S(t) - \beta S(t)I(t)dt + \mu dt - \mu S(t)dt \\ E(t+dt) = E(t) + \beta S(t)I(t)dt - \alpha E(t)dt - \mu E(t)dt \\ I(t+dt) = I(t) + \alpha E(t)dt - \gamma I(t)dt - \mu I(t)dt \\ R(t+dt) = R(t) + \gamma I(t)dt - \mu R(t)dt \end{cases}$$

3.3.2 Système différentiel

En faisant tendre dt vers 0, on obtient alors le système différentiel suivant :

$$\begin{cases} \frac{dS}{dt} = -\beta SI - \mu S + \mu \\ \frac{dE}{dt} = \beta SI - (\alpha + \mu)E \\ \frac{dI}{dt} = \alpha E - (\mu + \gamma)I \\ \frac{dR}{dt} = \gamma I - \mu R \end{cases}$$

Comme pour les deux études précédentes, on ne s'intéresse pas à la dernière équation qui peut être déduite des deux précédentes. On étudie donc le système différentiel :

$$\begin{cases} \frac{dS}{d\tau} = \mu - (\beta I + \mu)S \\ \frac{dE}{d\tau} = \beta SI - (\mu + \alpha)E \\ \frac{dI}{d\tau} = \alpha E - (\mu + \gamma)I \end{cases}$$

auquel on ajoute les conditions initiales :

$$S(0) = S_0, E(0) = 0 \text{ et } I(0) = I_0$$

3.3.3 Étude des équilibres

On s'intéresse à la jacobienne associée au système afin d'étudier les équilibres :

$$J(S, E, I) = \begin{bmatrix} -(\beta I + \mu) & 0 & -\beta S \\ \beta I & -(\mu + \alpha) & \beta S \\ 0 & \alpha & -(\mu + \gamma) \end{bmatrix}$$

Maintenant, intéressons-nous aux états de stabilité. Pour cela, on suppose qu'il n'y a plus de variations pour les différents compartiments. On se retrouve alors avec le système suivant :

$$\begin{cases} \mu = (\beta I + \mu)S \\ 0 = \beta SI - (\mu + \alpha)E \\ \alpha E = (\mu + \gamma)I \end{cases} \quad \begin{cases} I = \frac{1}{\beta}(\frac{\mu}{S} - \mu) \\ 0 = (\beta S - \frac{(\mu + \alpha)(\mu + \gamma)}{\alpha})I \\ E = \frac{\mu + \gamma}{\alpha}I \end{cases}$$

On distingue alors les deux cas d'annulation dans la deuxième équation :

- Si $I = 0$, alors on retrouve l'état d'équilibre $(S^*, I^*, E^*) = (1, 0, 0)$, la jacobienne associée vaut alors :

$$J(S^*, I^*, E^*) = \begin{bmatrix} -\mu & 0 & -\beta \\ 0 & -(\mu + \alpha) & \beta \\ 0 & \alpha & -(\mu + \gamma) \end{bmatrix}$$

En effectuant l'opération, $C_2 \leftarrow C_2 + \frac{\alpha}{\mu + \gamma}C_3$, on lit les valeurs propres de la jacobienne sur la diagonale qui sont alors :

$$(\lambda_1, \lambda_2, \lambda_3) = \left(-\mu, -(\mu + \alpha) + \frac{\alpha\beta}{\mu + \gamma}, -(\mu + \gamma) \right)$$

Cet état d'équilibre est asymptotiquement stable si et seulement si $-(\mu + \alpha) + \frac{\alpha\beta}{\mu + \gamma} < 0$, soit encore $(\mu + \alpha)(\mu + \gamma) > \alpha\beta$

- Si $I \neq 0$
Alors, on a $S^* = \frac{(\mu + \alpha)(\mu + \gamma)}{\alpha\beta}$. On pose alors le facteur R_0 défini par $S^* = \frac{1}{R_0}$.

On déduit I^* grâce à la première équation et E^* à partir de la dernière équation :

$$I^* = \frac{\mu(R_0 - 1)}{\beta}, E^* = \frac{\mu(\mu + \gamma)(R_0 - 1)}{\alpha\beta}$$

La jacobienne associée vaut alors :

$$J(S^*, E^*, I^*) = \begin{bmatrix} -(\mu(R_0 - 1) + \mu) & 0 & -\frac{\beta}{R_0} \\ \mu(R_0 - 1) & -(\mu + \alpha) & \frac{\beta}{R_0} \\ 0 & \alpha & -(\mu + \gamma) \end{bmatrix}$$

On effectue sur la jacobienne, l'opération $C_2 \leftarrow C_2 + \frac{\alpha}{\mu + \gamma} C_3$. On obtient la matrice équivalente :

$$J_1(S^*, E^*, I^*) = \begin{bmatrix} -\mu R_0 & -\frac{\alpha\beta}{R_0(\mu + \gamma)} & -\frac{\beta}{R_0} \\ \mu(R_0 - 1) & -(\mu + \alpha) + \frac{\alpha\beta}{R_0(\mu + \gamma)} & \frac{\beta}{R_0} \\ 0 & 0 & -(\mu + \gamma) \end{bmatrix}$$

On effectue ensuite l'opération $L_2 \leftarrow L_2 + (1 - \frac{1}{R_0})L_1$:

$$J_2(S^*, E^*, I^*) = \begin{bmatrix} -\mu R_0 & -\frac{\alpha\beta}{R_0(\mu + \gamma)} & -\frac{\beta}{R_0} \\ 0 & -(\mu + \alpha) + \frac{\alpha\beta}{R_0^2(\mu + \gamma)} & * \\ 0 & 0 & -(\mu + \gamma) \end{bmatrix}$$

Les valeurs propres de la jacobienne sont donc :

$$(\lambda_1, \lambda_2, \lambda_3) = \left(-\mu R_0, -(\mu + \alpha) + \frac{\alpha\beta}{R_0^2(\mu + \gamma)}, -(\mu + \gamma) \right)$$

L'état d'équilibre est donc asymptotiquement stable si et seulement si la seconde valeur propre est strictement négative, c'est-à-dire si et seulement si :

$$R_0^2 > \frac{\alpha\beta}{(\mu + \gamma)(\mu + \alpha)} = R_0$$

D'où le système est asymptotiquement stable si et seulement si $R_0 > 1$.

3.3.4 Simulations numériques

À nouveau, nous souhaitons compléter notre étude théorique par des simulations numériques. Le code se trouve également en annexe 7 du document.

Nous regardons tout d'abord l'évolution générale du modèle. Nous obtenons la figure 8. Comme pour le modèle SIR avec démographie, on voit que l'épidémie comporte plusieurs vagues : une première très forte au début (environ 50 jours), puis une deuxième plus faible (environ 200 jours). Finalement, le modèle se stabilise vers 400 jours, on obtient un état d'équilibre où une part de la population est tout le temps infectée ($I \neq 0$).

En suite, nous nous intéressons au plan de phase du système. Nous obtenons la figure 9. Indication de lecture : Il faut s'intéresser aux valeurs telles que $S(0) + E(0) + I(0) \leq 1$.

Conformément à notre analyse théorique, nous voyons apparaître un point d'équilibre attractif (toutes les flèches vont vers ce point) avec une petite partie de la population tout le temps exposée ou infectée, car nous sommes dans le cas $R_0 > 1$.




FIGURE 8 – Modèle SEIR avec démographie

Plan de phase SEIR(D) $\beta=0.3, \alpha=0.3, \gamma=0.1, \mu=0.009$




FIGURE 9 – Plan de phase pour SEIR avec démographie

4 Modèles compartimentaux et épidémie de zombies

4.1 Qu'est-ce qu'une épidémie de zombie ?

Les zombies viennent à l'origine de la culture afro-caribéenne et notamment de la culture vaudou. Les zombies étaient alors des personnes qui avaient été placées dans un état d'hibernation par l'effet d'une neurotoxine utilisée par un sorcier sur elles puis ramenées à la vie. L'hibernation entraînant de sévères dommages au cerveau, les zombies restaient alors sous le contrôle du sorcier.

De nos jours, les zombies ont bien changé pour devenir des corps réanimés insensibles à la douleur ayant pour seul objectif de transmettre l'infection ou plus simplement de se nourrir de chair vivante. Ils sont devenus très populaires à partir de 1968 avec le film de George Romero "La nuit des morts-vivants". L'intérêt autour des zombies a connu un nouvel essor dans les années 2000 et le genre continue à perdurer au travers de série comme The Walking Dead (2010-2022) ou des jeux-vidéos comme Resident Evil (1996-2020), Left 4 Dead (2008 et 2009) ou The Last Of Us (2013 et 2020 et adaptation en série en 2023).



Claqueur de The Last Of Us

Les zombies peuvent être assimilés aux infectés d'une épidémie. Nous avons alors souhaité nous pencher sur la modélisation d'une épidémie de zombies à partir des modèles à compartiment. Pour cela, nous avons travaillé sur un papier [Philip Munz(2009)] qui s'est intéressé à la même question. Ici, nous nous limiterons au modèle de base, mais d'autres modèles ont été proposés par [Philip Munz(2009)] notamment la mise en place d'un vaccin, d'une quarantaine ou d'attaques ciblées.


4.2 Susceptible, Zombies, Retirés

4.2.1 Modèle, schéma et système

Le modèle SZR est assez similaire au système SIR. À nouveau, on retrouve trois compartiments : les **Susceptibles**, les **Zombies** et les **Retirés**. La différence avec le modèle SIR se trouve au niveau des relations entre les compartiments.

- **L'infection d'un susceptible par un zombie.** On suppose que l'infection dépend d'un paramètre $\beta \in \mathbb{R}_+^*$, lié au taux de rencontre entre zombies et humains et la probabilité de transmission de l'infection.
- **La mort d'un zombie par l'action d'un susceptible.** Lorsqu'un humain rencontre un zombie, on suppose qu'il y a une probabilité $\alpha \in \mathbb{R}_+^*$ que ce dernier soit tué durant la rencontre et rejoigne le compartiment des retirés.
- **La résurrection d'un mort,** dépendant d'un paramètre $\zeta \in \mathbb{R}_+^*$.

Nous pouvons ainsi représenter le modèle avec le schéma suivant :



Pour notre modélisation mathématique, nous souhaitons exprimer l'évolution des compartiments dans le temps. On obtient le système suivant à l'instant $t + dt$ à partir des compartiments et relations posées :

$$\begin{cases} S(t+dt) = S(t) - \beta S(t)Z(t)dt \\ Z(t+dt) = I(t) + \beta S(t)Z(t)dt - \alpha Z(t)S(t)dt + \zeta R(t) \\ R(t+dt) = R(t) + \alpha Z(t)S(t)dt - \zeta R(t) \end{cases}$$

4.2.2 Système différentiel

On peut alors faire tendre le paramètre dt vers 0. On obtient le modèle **SZR**.

$$\begin{cases} \frac{dS}{dt} = -\beta SZ \\ \frac{dZ}{dt} = (\beta - \alpha)ZS + \zeta R \\ \frac{dR}{dt} = \alpha ZS - \zeta R \end{cases} \quad \text{avec } S(0) = S_0, \quad Z(0) = Z_0 \text{ et } R(0) = 0$$

4.2.3 Étude des équilibres

Pour étudier les équilibres, regardons la jacobienne associée au système différentiel :

$$J(S, Z) = \begin{bmatrix} -\beta Z & -\beta S & 0 \\ \beta Z - \alpha Z & \beta S - \alpha S & \zeta \\ \alpha Z & \alpha S & -\zeta \end{bmatrix}$$

Lorsque l'on suppose qu'il n'y a plus de variation, il ressort du système différentiel (plus précisément la première ligne) que l'on a deux équilibres possibles : $S = 0$ ou $Z = 0$. Étudions ces deux possibilités.

I. $Z = 0$

Dans ce cas, on a $R = 0$ et $S = 1$. Il s'agit de l'équilibre sans infection. On prend $(S^*, Z^*) = (1, 0)$. La jacobienne devient :

$$J(S^*, Z^*) = \begin{bmatrix} 0 & -\beta & 0 \\ 0 & \beta - \alpha & \zeta \\ 0 & \alpha & -\zeta \end{bmatrix}$$

On obtient alors $\chi_{J(S^*, Z^*)} = -\lambda(\lambda^2 + (\zeta - (\beta - \alpha)\lambda - \beta\zeta))$. On a donc toujours une valeur propre positive et donc cet équilibre est toujours instable.

II. $Z \neq 0$ donc $S = 0$ (aussi appelée fin du monde).

Dans ce cas, on a $R = 0$ et $Z = 1$. On prend donc $(S^*, Z^*) = (0, 1)$. La jacobienne devient :

$$J(S^*, Z^*) = \begin{bmatrix} -\beta & 0 & 0 \\ \beta - \alpha & 0 & \zeta \\ \alpha & 0 & -\zeta \end{bmatrix}$$

On obtient alors $\chi_{J(S^*, Z^*)} = -\lambda(-\beta - \lambda)(-\zeta - \lambda)$ et donc les valeurs propres sont :

$$(\lambda_1, \lambda_2, \lambda_3) = (0, -\beta, -\zeta)$$

On a donc un équilibre stable, mais pas de stabilité asymptotique, car λ_1 est nulle.

4.2.4 Simulations numériques

À nouveau, nous souhaitons compléter notre étude théorique par des simulations numériques. Le code se trouve également en annexe 7 du document.

Tout d'abord, regardons l'évolution générale d'une épidémie de zombies à Rennes (222 000 habitants) partant à chaque fois d'un seul individu zombifié, mais avec différents paramètres de résistance de la population. Nous avons regardé trois cas : une population qui se défend plutôt normalement, l'humain tue le zombie dans 90% des rencontres et se fait contaminer dans les 10% restants, une population un peu moins résistante (70% de réussite lors d'un combat et 30% de contamination) et enfin une population très résistante (95% de réussite lors d'un combat et 5% de contamination). Nous avons obtenu les figures suivantes 10.




FIGURE 10 – Modélisation d'une épidémie de zombies pour la ville de Rennes

On observe l'apparition d'un pic de retirés qui coïncide avec le croisement des courbes des zombies et des susceptibles. Mais ce que l'on voit surtout, c'est que dans les trois cas, la population saine finie par disparaître après une certaine durée. Plus la population est résistante, plus les zombies prennent de temps pour prendre le dessus. Cela correspond bien à la théorie.

Il semblerait que l'apocalypse zombie soit inévitable d'après le modèle SZR.

5 Critique des modèles SIR et SEIR

5.1 La difficulté de paramétrage

Les modèles SIR, SIR avec démographie et SEIR avec démographie dépendent de plusieurs paramètres : β, γ, α et μ . Cependant, au début d'une épidémie, on ne connaît pas les valeurs de ces paramètres, on peut seulement les estimer à partir des premières

données que l'on recueille et pour certains paramètres, comme l'efficacité d'un futur vaccin, il est impossible d'avoir une estimation. De plus, l'estimation des paramètres est dépendante de la qualité des données recueillies, mais il est parfois difficile d'avoir des données correctes. En effet, il peut être complexe de compter clairement le nombre d'infectés, les personnes asymptomatiques ne se faisant pas forcément dépister, ou de compter correctement les décès qui peuvent être en réalité dus à d'autres affections. Les modèles compartimentaux ne peuvent être correctement paramétrés qu'*a posteriori* ou alors, il est nécessaire de les réviser régulièrement pour les faire coïncider sur les dernières données observées. L'estimation est également d'autant plus complexe que le nombre de compartiments et de relations augmente. Il est donc nécessaire de trouver un juste milieu entre un nombre plus important de compartiment qui permet d'être plus fidèle à la réalité et la difficulté de paramétrage qui en découle.

5.2 Hypothèses sur les compartiments et les relations

Au cours de notre modélisation avec les modèles à compartiments, nous avons fait plusieurs hypothèses pour simplifier notre modélisation. Nous allons voir en quoi ces hypothèses peuvent ne pas représenter fidèlement la réalité.

Tout d'abord, nous avons fait l'hypothèse de l'homogénéité de la population et des contacts entre individus. Nous avons supposé que chaque catégorie de population (retraités, enfants, etc) a la même probabilité de rencontrer n'importe quelle autre. Or cela n'est pas du tout vrai dans la réalité par notre voisinage, notre travail, nos loisirs, etc. De plus, le nombre et le type de contact varient selon chacun (âge, tempérament...) et les moments de l'année (Noël, Jeux Olympiques...). Pour prendre en compte ces aspects, il est possible de mettre en place de nouveaux compartiments et d'utiliser une matrice de contact associant la probabilité de transmissions entre chaque compartiment, mais cela vient complexifier le paramétrage.

Une autre hypothèse que nous avons faite était celle de la répartition homogène dans l'espace : chaque individu a la même probabilité d'en rencontrer un autre sans notion de distance ou de densité de population locale. À nouveaux, cette hypothèse ne correspond pas à la réalité dans laquelle on voit apparaître des foyers infectieux (clusters) notamment lorsque l'on se place à une grande échelle comme celle d'une région ou d'un pays.

Enfin, une autre problématique vient de la manière dont nous avons pris en compte le temps. Nous avons par exemple fait l'hypothèse qu'un individu, dès lors qu'il entre dans le compartiment des infectés, transmet l'agent pathogène de la même manière que tous les autres infectés sans prendre en compte par exemple l'augmentation progressive de la charge virale et donc l'augmentation de la probabilité de transmission de l'agent pathogène ou à l'inverse la diminution pour un infecté en cours de guérison.

6 Conclusion

Au cours de ce rapport, nous avons vu plusieurs versions de modèles à compartiments. Nous avons tout d'abord étudié le modèle SIR, nous avons vu qu'il possédait une infinité de points d'équilibre de la forme $(S^*, I^*) = (\alpha, 0)$ avec $\alpha \in [0; 1]$ qui sont tous stables et nous avons pu étudier l'impact des différents paramètres du système (β, γ) sur une épidémie. Nous nous sommes en suite intéressés au modèle SIR avec démographie pour prendre en compte ce paramètre que nous avons initialement exclu. Nous avons alors montré que le modèle SIR avec démographie possède deux points d'équilibre $I \neq 0$ et $I = 0$ qui chacun présentaient des conditions nécessaires et suffisantes pour obtenir un équilibre asymptotiquement stable. Nous avons alors confirmé, lors de nos simulations numériques pour le cas $I \neq 0$, la présence de plusieurs vagues de contamination de moins en moins fortes et la stabilisation du modèle où une partie de la population était toujours infectée. Enfin, nous avons travaillé sur le modèle SEIR avec démographie pour prendre en compte la période d'incubation du virus. Nous avons alors trouvé deux points d'équilibre, tous les deux asymptotiquement stables selon des conditions liées aux paramètres du modèle. Tout comme pour le modèle SIR avec démographie, nous avons simulé numériquement le point d'équilibre où une partie de la population est toujours exposée ou infectée.

Ensuite, nous nous sommes un peu écartés des épidémies ordinaires pour nous intéresser à la modélisation d'une épidémie de zombies. Nous avons alors travaillé sur un modèle à compartiments SZR pour lequel nous avons trouvé deux points d'équilibre : $Z = 0$ qui était instable et $S = 0$ qui était toujours stable, mais sans stabilité asymptotique. Nous avons alors fait des simulations pour comparer différentes populations selon leur résistance pour le cas $Z \neq 0$ et nous avons vu que la population humaine finissait toujours par disparaître après un temps plus ou moins court. D'autres modèles avec d'autres compartiments et d'autres relations comme la mise en quarantaine ou la création d'un vaccin sont proposés dans [Philip Munz(2009)] et permettent d'aller plus loin dans la modélisation d'une apocalypse zombie.

Enfin, nous avons parlé des limites des modèles à compartiments et notamment de la problématique de paramétrage ainsi que des problématiques liées aux hypothèses trop éloignées de la réalité que nous avons faites.

Bien entendu, il existe d'autres types de modèles. Nous pouvons notamment citer les modèles à compartiments aléatoires (en opposition aux modèles déterministes que nous avons étudiés) qui permettent d'assouplir nos hypothèses et faciliter le paramétrage, mais qui donnent un intervalle plutôt qu'une valeur. Une autre possibilité est à chercher du côté de la physique des particules qui permet notamment de prendre en compte la dimension spatiale des épidémies.

Références

[Berthelin(2017)] F. Berthelin. *Equations différentielles*. Cassini, 2017.

- [Chill(2007)] R. Chill. Equations différentielles et stabilité, 2007. URL <https://tu-dresden.de/mn/math/analysis/chill/ressourcen/dateien/skripte/EquationsDifferentiellesChill.pdf?lang=en>.
- [Demailly(2012)] J.-P. Demailly. *Analyse numérique et équations différentielles*. EDP Sciences, 2012.
- [Philip Munz(2009)] J. I. . R. J. S. Philip Munz, Ioan Hudea. When zombies attack! : Mathematical modelling of an outbreak of zombie infection dans infectious disease modelling research progress, 2009. URL <http://math.uchicago.edu/~shmuel/Modeling/WHEN%20ZOMBIES%20ATTACK!-%20MATHEMATICAL%20MODELLING%20OF%20AN%20OUTBREAK%20OF%20ZOMBIE%20INFECTION.pdf>.

7 Annexe

Les codes peuvent également être retrouvés sur GitHub.
Dans l'ensemble de nos codes, nous utiliserons les bibliothèques numpy, scipy et matplotlib.

```
import numpy as np
from scipy.integrate import odeint
import matplotlib.pyplot as plt
```

SIR

```
def SIR(gamma,beta,S0,I0,R0,dt,seuil):
    S = [S0]
    I = [I0]
    R = [R0]
    i = 1

    while I[-1] >= seuil or i < 20:
        S.append(S[i - 1] - beta * S[i - 1] * I[i - 1] * dt)
        I.append(I[i - 1] + beta * S[i - 1] * I[i - 1] * dt - gamma * I[i - 1]
                * dt)
        R.append(R[i - 1] + gamma * I[i - 1] * dt)
        i = i+1
    return S, I, R

def affiche_SIR(S,I,R,dt,title):
    plt.title(title)
    taille = len(I)
    t = np.linspace(0,taille*dt,taille)
    plt.plot(t, S, '-', label='S(t)')
    plt.plot(t, I, '-', label='I(t)')
    plt.plot(t, R, 'r--', label='R(t)')
    plt.legend()
    plt.grid()
```

```

plt.show()

# Impact de beta
gamma = 0.1 #remission
beta_1 = 0.5 #contamination
beta_2 = 0.3
N = 10000
T = 100
dt = T/N
S0 = 0.999
I0 = 0.001
R0 = 0

S,I,R = SIR(gamma,beta_1,S0,I0,R0,dt,0.0005)
affiche_SIR(S,I,R,dt,'S(t), I(t), R(t), beta = 0.5, gamma = 0.1, seuil =
0.05%')

S,I,R = SIR(gamma,beta_2,S0,I0,R0,dt,0.0005)
affiche_SIR(S,I,R,dt,'S(t), I(t), R(t), beta = 0.3, gamma = 0.1, seuil =
0.05%')

# Impact d'un confinement
gamma = 0.1 #remission
beta = 0.35 #contamination hors confinement
beta_c = 0.2 #contamination en confinement
S0 = 0.999
I0 = 0.001
R0 = 0
N = 10000
T = 100
dt = T/N
t1 = [7+5*i for i in range(0,6)] #fin du confinement

def SIR_confinement(gamma,beta,beta_c,S0,I0,dt,seuil,debut_conf):
    S = [S0]
    I = [I0]
    i = 1
    while I[-1] >= seuil or i < 20:
        if i * dt < debut_conf or i * dt > debut_conf+25:
            S.append(S[i - 1] - beta * S[i - 1] * I[i - 1] * dt)
            I.append(I[i - 1] + beta * S[i - 1] * I[i - 1] * dt - gamma * I[i
            - 1] * dt)
        else:
            S.append(S[i - 1] - beta_c * S[i - 1] * I[i - 1] * dt)
            I.append(I[i - 1] + beta_c * S[i - 1] * I[i - 1] * dt - gamma *
            I[i - 1] * dt)
        i = i+1
    return S, I

S_sans_conf,I_sans_conf,R_sans_conf = SIR(gamma,beta,S0,I0,R0,dt,0.0005)

```

```

taille = len(I_sans_conf)
t = np.linspace(0,taille*dt,taille)
plt.plot(t, I_sans_conf, '--', label='I(t) sans confinement')

for debut_conf in t1:
    Sc, Ic = SIR_confinement(gamma,beta,beta_c,S0,I0,dt,0.0005,debut_conf)
    taille = len(Ic)
    t = np.linspace(0, taille * dt, taille)
    plt.plot(t, Ic, '--', label='I_c(t), t1 = '+str(debut_conf))

plt.title('I(t) avec et sans confinement')
plt.legend()
plt.grid()
plt.show()

# Impact de gamma
beta = 0.5
S0 = 0.999
I0 = 0.001
R0 = 0
N = 10000
T = 100
dt = T/N
for gamma in [0.1,0.2,0.3,0.4]:
    S, I, R = SIR(gamma,beta,S0,I0,R0,dt,0.0005)
    taille = len(I)
    t = np.linspace(0, taille * dt, taille)
    plt.plot(t, I, '--', label='I_c(t), gamma = {:.1f}'.format(gamma))
plt.title('I(t) pour differentes valeurs de gamma')
plt.legend()
plt.grid()
plt.show()

# Meme R_0 = 1.2 mais differentes valeurs de beta et gamma
dt = T/N
S0 = 0.999
I0 = 0.001
R0 = 0
couples_beta_gamma = [[1/3,0.2],[2/3,0.4],[0.5,0.3],]
I_R0 = []
for couple in couples_beta_gamma:
    beta, gamma = couple[0], couple[1]
    S, I, R = SIR(gamma,beta,S0,I0,R0,dt,0.0005)
    taille = len(I)
    t = np.linspace(0,taille*dt,taille)
    plt.plot(t,I, '--', label=('beta = '+str(round(beta,2))+ ' gamma = '+str(round(gamma,2))))
plt.title('I(t) avec R0 = 5/3, seuil = 0.05% et differents couples beta/gamma')
plt.legend()

```

```

plt.grid()
plt.show()

# Plan de phase
from phaseportrait import PhasePortrait2D

beta = 0.5
gamma = 0.3
def variations(S,I):
    return - beta*S*I, beta*S*I - gamma*I

SIR_phase = PhasePortrait2D(variations, [[0,1],[0,1]],color='viridis',
    Title='Plan de phase du modele SIR', xlabel='Susceptibles',
    ylabel='Infectes')
fig, ax = SIR_phase.plot()

# Ajouter la diagonale
x_coords = np.linspace(0, 1, 100)
y_coords = 1 - x_coords
ax.plot(x_coords, y_coords, color='black', linestyle='--') # Tracer la
    diagonale en rouge en pointilles

fig.show()

```

SIR avec démographie

Modélisation pour chaque compartiment :

```

import numpy as np
import matplotlib.pyplot as plt

mu = 0.009 #mortalite et natalite
gamma = 0.2 #remission
beta = 0.4 #contamination
N = 100000
T = 600

S0 = 0.999
I0 = 0.001
R0 = 0

S = np.zeros(N)
I = np.zeros(N)
R = np.zeros(N)
t = np.linspace(0, T, N)

dt = T/N

S[0]=S0

```



```

I[0]=I0
R[0]=R0

for i in range(0,N-1):
    S[i+1] = S[i] - beta*S[i]*I[i]*dt + mu*dt - mu*S[i]*dt
    I[i+1] = I[i] + beta*S[i]*I[i]*dt - gamma*I[i]*dt - mu*I[i]*dt
    R[i+1] = R[i] + gamma*I[i]*dt - mu*R[i]*dt

plt.title('S(t), I(t), R(t), beta = 0.4, gamma = 0.2, mu = 0.009, R0 > 1')
plt.plot(t, S, '-', label='S(t)')
plt.plot(t, I, '-', label='I(t)')
plt.plot(t, R, 'r--', label='R(t)')
plt.legend()
plt.grid()
plt.show()

```

Plan de phase :

```

from phaseportrait import PhasePortrait2D

mu = 0.05
beta = 0.3
gamma = 0.3

def variations(S,I):
    return mu - mu*S - beta*S*I, beta*S*I - gamma*I - mu*I

SIR_phase = PhasePortrait2D(variations, [[0,1],[0,1]],color='viridis',
    Title='Plan de phase du modele SIR demographique beta=0.3, gamma=0.3,
    mu=0.05, R0<1', xlabel='Susceptibles', ylabel='Infectes')
fig, ax = SIR_phase.plot()

# Ajouter la diagonale
x_coords = np.linspace(0, 1, 100)
y_coords = 1 - x_coords

ax.plot(x_coords, y_coords, color='black', linestyle='--')

fig.show()

```

SEIR avec démographie

```

import numpy as np
import matplotlib.pyplot as plt

mu = 0.009 #mortalite et natalite

```

```

gamma = 0.1 #remission
beta = 0.4 #contamination
alpha = 0.3 #incubation
N = 100000
T = 700

S0 = 0.999
E0 = 0.0005
I0 = 0.0005
R0 = 0

S = np.zeros(N)
E = np.zeros(N)
I = np.zeros(N)
R = np.zeros(N)
t = np.linspace(0, T, N)

dt = T/N

S[0]=S0
E[0]=E0
I[0]=I0
R[0]=R0

for i in range(0,N-1):
    S[i+1] = S[i] - beta*S[i]*I[i]*dt + mu*dt - mu*S[i]*dt
    E[i+1] = E[i] + beta*S[i]*I[i]*dt - alpha*E[i]*dt - mu*E[i]*dt
    I[i+1] = I[i] + alpha*E[i]*dt - gamma*I[i]*dt - mu*I[i]*dt
    R[i+1] = R[i] + gamma*I[i]*dt - mu*R[i]*dt

plt.title('S(t), I(t), R(t), beta = 0.4, alpha = 0.3, gamma = 0.1, mu =
    0.009, R0 > 1')
plt.plot(t, S, '-', label='S(t)')
plt.plot(t, E, '-', label='E(t)')
plt.plot(t, I, '-', label='I(t)')
plt.plot(t, R, 'r--', label='R(t)')
plt.legend()
plt.grid()
plt.show()

```

Plan de phase

```

from phaseportrait import PhasePortrait3D

mu = 0.009 #mortalite et natalite
gamma = 0.1 #remission
beta = 0.4 #contamination
alpha = 0.3 #incubation

```

```

def variations(S,E,I):
    return mu - mu*S - beta*S*I, beta*S*I - alpha*E, alpha*E - gamma*I - mu*I

SIR_phase = PhasePortrait3D(variations, Range=[[0,1],[0,1],[0,1]],
    color='viridis', Title='Plan de phase SEIR(D) beta=0.3, alpha=0.3,
    gamma=0.1, mu=0.009', xlabel='Susceptibles',
    ylabel='Exposes',zlabel='Infectedes')
fig, ax = SIR_phase.plot()
fig.show()

```

SZR

```

import numpy as np
import matplotlib.pyplot as plt

def SZR(beta, alpha, zeta, S0,Z0,R0,dt,seuil):
    S = [S0]
    Z = [Z0]
    R = [R0]
    i = 1

    while S[-1] > seuil :
        S.append(S[i - 1] - beta * S[i - 1] * Z[i - 1] * dt)
        Z.append(Z[i - 1] + beta * S[i - 1] * Z[i - 1] * dt - alpha * Z[i -
            1]*S[i-1] * dt + zeta*R[i-1])
        R.append(R[i - 1] + alpha * Z[i - 1] * S[i-1] * dt - zeta*R[i-1])
        i = i+1
    return S, Z, R

def affiche_SZR(S,Z,R,dt,title):
    plt.title(title)
    taille = len(Z)
    t = np.linspace(0,taille*dt,taille)
    plt.plot(t, S, '-', label='S(t)')
    plt.plot(t, Z, '-', label='Z(t)')
    plt.plot(t, R, 'r--', label='R(t)')
    plt.legend()
    plt.grid()
    plt.show()

# Impact de beta
N = 10000
T = 100
dt = T/N

S0Rennes = (222485 - 1)/222485
Z0Rennes = 1/222485
R0Rennes = 0

```

```

S,Z,R = SZR(0.1,0.9,0.01,S0,Z0,R0,dt,0.000001)
affiche_SZR(S,Z,R,dt,'S(t), I(t), R(t), b = 0.1, a = 0.9, z = 0.01, seuil =
    0.0001%')

SRennes,ZRennes,RRennes =
    SZR(0.1,0.9,0.01,SRennes,Z0Rennes,R0Rennes,dt,0.000001)
affiche_SZR(SRennes,ZRennes,RRennes,dt,'Rennes, b = 0.1, a = 0.9, z = 0.01,
    seuil = 0.0001%')

SRennes_fort,ZRennes_fort,RRennes_fort = SZR(0.05, 0.95,
    0.01,SRennes,Z0Rennes,R0Rennes,dt,0.000001)
affiche_SZR(SRennes_fort,ZRennes_fort,RRennes_fort,dt,'Rennes, b = 0.05, a =
    0.95, z = 0.01, seuil = 0.0001%')

SRennes_nuls,ZRennes_nuls,RRennes_nuls = SZR(0.3, 0.7,
    0.01,SRennes,Z0Rennes,R0Rennes,dt,0.000001)
affiche_SZR(SRennes_nuls,ZRennes_nuls,RRennes_nuls,dt,'Rennes, b = 0.3, a =
    0.7, z = 0.01, seuil = 0.0001%')

```

Plan de phase

```

from phaseportrait import PhasePortrait3D

beta = 0.1
alpha = 0.9
zeta = 0.1
def variations(S,Z,R):
    return -beta*Z*S, beta*S*Z - alpha*Z*S + zeta*R, alpha*Z*S - zeta*R

SZR_phase = PhasePortrait3D(variations, Range=[[0,1],[0,1],[0,1]],
    color='viridis', Title='Plan de phase SZR b=0.3, a=0.3, g=0.1, mu=0.009',
    xlabel='Susceptibles', ylabel='Zombies',zlabel='Retires')
fig, ax = SZR_phase.plot()
fig.show()

```

Une citation

"Personnellement, je ne crois pas que la modélisation mathématique prédictive soit de nature scientifique, je pense qu'il s'agit d'une prophétie moderne comme l'a été l'astrologie à un moment donné, utilisant les données de l'astrophysique"

- Didier Raoult, *Le Point* du 3 mars 2016.