

Perspectiva – Mesure de la qualité d'une extraction d'idées réalisée par un modèle de langue


Application aux consultations publiques à questions ouvertes

*Matthias Mazet, Garance Malnoë & Yannis Petit
encadré par Cyril François*



I. Introduction – Contexte

- **Consultations publiques** = outils permettant de recueillir l'avis d'une population via des questions.
 - **Questions fermées :**
 - **Avantages** : analyse **simple et rapide**, peu coûteux.
 - **Inconvénients** : réponses restreintes, **peu élaborées**, parfois ambiguës.
 - **Questions ouvertes :**
 - **Avantages** : réponses variées, **opinions nuancées**.
 - **Inconvénients** : **coûteux**, analyse **longue** et fastidieuse, **temporalité contraignante**.



I. Introduction – Contexte


- **Solution** envisageable pour traiter les questions ouvertes : **outils numériques**.
 - Utiliser les LLM pour **automatiser** et **accélérer** l'analyse, produire des synthèses, etc.
 - **Allier le numérique à l'humain** (≠ remplacer l'humain par le numérique).
 - **Exemples concrets** :
 - Projet ouvert **Plurality**¹ = développement de technologies collaboratives et décentralisées.
 - Renforcer la participation démocratique.
 - Renforcer la délibération collective.
 - Renforcer la protection des droits numériques.
 - Outil open source **Talk To The City**² = méthodes de traitement automatique du langage.
 - Analyser les contributions citoyennes.
 - Structurer les opinions exprimées lors de consultations publiques.

1. E.Glen Weyl, Audrey Tang and Plurality Community, *Plurality : The future of collaborative technology and democracy*

2. AI Objectives Institute, *Talk to the city*

I. Introduction – Objectifs des travaux

- **Perspectiva**³ = continuité de la démarche de numérisation.
 - Utiliser les outils numériques pour **mieux comprendre ce qu'un large groupe peut penser.**
 - **Problème** principal actuel : **qualité des extractions inconnue.**
- **Nos travaux :**
 - **Recherche** et **validation** de métriques permettant de contrôler la qualité d'extraction d'un LLM.
 - Synthèse dans un **pipeline d'extraction et de traitement.**
 - Étude de l'**influence du LLM** sur la qualité d'extraction.



3. Cyril François, *Perspectiva – Utiliser les outils LLM pour analyser et fournir un retour plus rapide et fidèle aux contributeurs d'une consultation publique*


II. Données et protocole

- Données utilisées ⁴ : issues du **Grand Débat National**.
 - Disponible en **libre accès** sur data.gouv.fr
 - Question n°163 : **“Que faudrait-il faire pour rendre la fiscalité plus juste et plus efficace ?”**
 - ~154 000 contributions utilisables sur ~186 000 participations.
 - → Analyse restreinte aux **200 premières contributions** (échantillon représentatif).
 - Longueur des contributions trop éparées → Création de classes de longueur.



- 2 millions de contributeurs.
- 12 millions d'euros.

Fig. 3 – logo et indicateurs du Grand Débat National



4. Eric Buge and Camille Morio, *Le grand débat national, apports et limites pour la participation citoyenne*, 2019

II. Données et protocole


- **Protocole**⁵ :

1. **Extraction** des idées de chaque contribution via un LLM.
2. **Calcul de la métrique** sélectionnée sur chaque extraction.
3. **Notation manuelle** de l'extraction :
 - i. **Notation** par chacun des trois membres du groupe (règles pré-établies en amont).
 - ii. **Marquage** de la présence d'**hallucinations**.
 - iii. **Marquage** de la présence d'**idées séparées**.
4. Calcul des **corrélations entre chaque annotateur**.
5. Agrégation des notes humaines en un "**score humain**" → Moyenne des trois notes humaines.
6. Calcul de la **corrélation** entre le **score humain** et la **métrique sélectionnée**.


5. Ehud Reiter, *How to validate metrics*

II. Données et protocole

- Idées séparées :



- Hallucinations :



III. Travaux – Métrique QualIT

- **Métrique QualIT**⁶ = Qualitative Insight Tool.

$$C_i = \frac{1}{n} \sum_{j=1}^n \frac{V_{inp,ij} \cdot V_{key,ij}}{|V_{inp,ij}| \cdot |V_{key,ij}|}, \text{ avec } \begin{cases} C_i & \text{le score QualIT de la } i^e \text{ contribution.} \\ n & \text{la dimension de l'espace d'embedding.} \\ V_{inp,ij} & \text{la } j^e \text{ coordonnée du vecteur d'embedding de la} \\ & i^e \text{ contribution.} \\ V_{key,ij} & \text{la } j^e \text{ coordonnée du vecteur d'embedding des idées} \\ & \text{extraites de la } i^e \text{ contribution.} \\ |\cdot| & \text{une norme euclidienne.} \end{cases}$$

- Corrélation de Pearson : **0.71**.
- Tendance à la **sur-notation**.
- **Mauvaise détection** des hallucinations et des idées séparées.
- **Idée intéressante mais imparfaite seule.**




Fig. 7 – Score humain selon le score QualIT


6. Kapoor S. et al., *Qualitative Insights Tool (QualIT): LLM Enhanced Topic Modeling*, 2024

III. Travaux – Métriques ROUGE

- **Métriques ROUGE**⁷ = Recall-Oriented Understudy for Gisting Evaluation.
- Quantifier dans quelle mesure le contenu lexical de l'extraction recouvre celui du texte source.


- **ROUGE-N (N = 1) :**

- **Chevauchement de n-grammes** entre la référence et le texte généré.
- Corrélation de Pearson : **0.79**.
- Évalue bien les scores extrêmes.



- **ROUGE-L :**

- Basée sur le **LCS** (plus longue sous-séquence commune).
- Corrélation de Pearson : **0.78**.
- Tendance à bien évaluer les scores extrêmes.




- **Métriques intéressantes pour les extractions avec des scores extrêmes.**

7. Chin-Yew Lin, Rouge : A package for automatic evaluation of summaries. In Proceedings of the ACL Workshop on Text Summarization Branches Out, 2004.

III. Travaux – Métrique NLI

- **Métriques NLI**⁸ = Natural Language Inference.
- Déterminer la **relation inférentielle** qui relie une **prémisse p** et une **hypothèse h**.
- Trois relations classiquement distinguées :
 - **Entailment (E)** : h est entraînée par p.
 - Dans toute situation compatible avec p, h est également vraie.
 - **Contradiction (C)** : h est incompatible avec p.
 - Si p est vraie, alors h doit être fausse.
 - **Neutral (N)** : h n'est ni entraînée ni contredite par p.
 - La vérité de h reste indéterminée relativement à p.



8. Blanck et al., *Reverse-engineering nli : A study of the meta-inferential properties of natural language inference*, 2026

III. Travaux – Métriques NLI

- **Approximation lexicale** (sans réseau de neurones) :

- Extraction fiable si fortement similaire à au moins une phrase du texte **ET** ne présente pas d'inversion de sens.
- Construction de la métrique :

- **Support :**

$$support(h_i) = \max_j (0.6 \cdot J(h_i, p_j) + 0.4 \cdot LCS(h_i, p_j)), \text{ avec } \begin{cases} J & \text{le score de Jaccard} \\ LCS & \text{le score LCS} \\ h_i & \text{la } i^e \text{ idé e extraite de la contribution} \\ p_j & \text{la } j^e \text{ phrase de la contribution} \end{cases}$$

- **Contradiction :** $contra(h_i) = 1[neg(h_i) \neq neg(p_{j^*})] \cdot (1 - support(h_i)) \cdot \alpha, \alpha \in [0; 1]$

- **Agrégation :**


$$\begin{aligned} NLI_{support}(p) &= \frac{1}{n} \sum_{i=1}^n support(h_i) \\ NLI_{contra}(p) &= \frac{1}{n} \sum_{i=1}^n contra(h_i) \end{aligned} \quad \left. \begin{array}{l} \text{---} \\ \text{---} \end{array} \right\} \rightarrow NLI_{final}(p) = \max[0; \min[1; NLI_{support}(p) - NLI_{contra}(p)]]$$

- **Modèle NLI pré-entraîné** (RoBERTa) :


- Modèle roberta-large-snli_mnli_fever_anli.
- Fournit directement Entailment, Contradiction et Neutral.

III. Travaux – Métriques NLI

- **NLI final (approximation lexicale) :**
 - Corrélation de Pearson : **0.52**.
 - Tendance à **sous-évaluer** les scores humains.



- **NLI RoBerta final :**
 - Corrélation de Pearson : **0.51**.
 - Tendance à **sur-évaluer** les scores humains **faibles**.
 - Attribut des **valeurs extrêmes** aux extractions.



- **Idée intéressante mais résultats décevants.**



III. Travaux – Pipeline

- **Pipeline de traitement** des contributions = cadre expérimental synthétisant nos travaux.
- **But** : réaliser de manière **automatique** l'ensemble de notre travail :
 - **Extraction d'idées** via un LLM et un prompt choisis.
 - **Notation des extractions** selon les différentes métriques analysées.
 - **Filtre des extractions** selon le rendu souhaité (toutes les extractions, juste les très bonnes, etc.).
- Pipeline **très flexible** pour garantir son intégrabilité et sa réutilisation au sein de *Perspectiva*.
- Exemples d'utilisation :
 - **Comparaison de LLM** et/ou prompt en terme de qualité d'extraction.
 - Construction de **jeux de données modulables** (filtre sur les métriques).

III. Travaux – Comparaison de LLM


- Pour aller plus loin : **étude de l'influence du choix du modèle de langue.**
- **Hypothèses :**
 - **Moins d'hallucinations.**
 - Des extractions de **meilleure qualité.**
 - **Les métriques détectent bien l'éventuelle augmentation de qualité.**
- **Difficulté :** Comment obtenir l'accès à un plus gros modèle ?
 - Sur nos machines personnelles : limitations techniques en RAM et VRAM.
 - Pas d'accès gratuit à des serveurs de calcul.
- **Solution :** Appel à un serveur de calcul payant.
 - → Google Cloud Platform : **VertexAI** et **Gemini 3 Pro.**

III. Travaux – Comparaison de LLM




- **Qualité plus élevée** et plus **homogène**.
 - Surtout pour les contributions **très courtes et longues** :
 - Très courtes → **beaucoup moins d'hallucinations** (1 avec Gemini 3 pro vs 66 avec Llama 8B).
 - Longues → **meilleure capacité de synthèse**.
- 12 erreurs liées à une absence de réponse du serveur VertexAI.
- Aucune erreur liée au non-respect du format.

III. Travaux – Comparaison de LLM



- Scores **plus élevés** pour l'ensemble des métriques.
- Phénomène de resserrement → scores **plus homogènes**.
- → Les métriques **capturent bien l'augmentation de qualité** des extractions avec le nouveau modèle.



- **Véritable intérêt à l'utilisation de plus gros modèles.**

IV. Enjeux sociaux et environnementaux

- **Enjeux environnementaux globaux :**

- Utilisation à grande échelle des LLM + démocratisation de ces outils → répercussions globales importantes.
- Encouragement de l'utilisation de plus gros modèles → course à l'entraînement de modèles toujours plus performants et gourmands en ressources (électricité, eau, ...).

- **Enjeux sociaux globaux :**

- **Perspectives vertueuses** : redynamisation du débat public, gouvernance plus horizontale.
- **Potentielles dérives** : simplification des idées à l'extrême, délégation excessive, décisions opaques.
- **Enjeux importants** : représentativité, transparence, absence de biais, souveraineté numérique.

V. Conclusion et perspectives

- **Résultats :**
 - **Métriques et pipeline :**
 - Scores NLI globalement décevants.
 - QualIT et ROUGE (1 et L) plutôt intéressants → intégration au pipeline.
 - **Choix du LLM :**
 - Plus gros LLM = meilleure qualité d'extraction.
 - → Compromis coût/qualité.
- **Pistes** pour la suite du projet *Perspectiva* :
 - **Amélioration du prompt.**
 - Étude de **l'influence du choix des seuils** dans le pipeline sur la formation des méta-idées.

Sources

1. E.Glen Weyl, Audrey Tang and Plurality Community, *Plurality : The future of collaborative technology and democracy*.
2. AI Objectives Institute, Talk to the city.
3. Cyril François, *Perspectiva – Utiliser les outils LLM pour analyser et fournir un retour plus rapide et fidèle aux contributeurs d'une consultation publique*.
4. Eric Buge and Camille Morio, *Le grand débat national, apports et limites pour la participation citoyenne*, 2019.
5. Ehud Reiter, *How to validate metrics*.
6. Kapoor S. et al., *Qualitative Insights Tool (QualIT): LLM Enhanced Topic Modeling*, 2024.
7. Chin-Yew Lin, *Rouge : A package for automatic evaluation of summaries. In Proceedings of the ACL Workshop on Text Summarization Branches Out*, 2004.
8. Blanck et al., *Reverse-engineering nli : A study of the meta-inferential properties of natural language inference*, 2026.