

Mesure de la qualité d'une extraction d'idées réalisée par un modèle de langue

Application aux consultations publiques à questions ouvertes

Matthias MAZET, Garance MALNOË & Yannis PETIT
encadré·e·s par Cyril FRANÇOIS

Table des matières

1	Introduction	1
1.1	Contexte	1
1.2	Objectif des travaux	2
2	Données et Méthodes	3
2.1	Organisation et gestion de projet	3
2.2	Données	3
2.3	Protocole d'extraction et d'évaluation	5
2.4	Métriques	6
2.5	Pipeline	11
2.6	Influence du LLM d'extraction	12
3	Résultats et discussion	12
3.1	Extractions et notation humaine	12
3.2	Métrique QualIT	15
3.3	Métrique ROUGE	18
3.4	Métrique NLI	22
3.5	Pipeline	27
3.6	Influence du LLM d'extraction	28
4	Enjeux sociétaux et environnementaux	30
4.1	Politique de la structure d'accueil : Data For Good	30
4.2	Enjeux environnementaux personnels	31
4.3	Enjeux environnementaux globaux	32
4.4	Enjeux sociaux globaux	32
5	Conclusion	34
	Références	37
6	Annexe	38



1 Introduction

1.1 Contexte

Les consultations publiques représentent de puissants outils pour les élus et les organismes publics, mais également pour les citoyens. En effet, d'une part, elles permettent aux citoyens d'exprimer leurs attentes et leurs priorités et, d'autre part, elles permettent aux décideurs de mieux comprendre le point de vue des masses. Ainsi, ces derniers peuvent récolter de précieuses informations sur des problématiques spécifiques, accéder à leur réalité concrète et aux contraintes du terrain, et en conséquence réduire le décalage souvent perçu entre les politiques publiques implémentées et les besoins réels de la population.

Dans leur forme la plus simple, les consultations publiques s'appuient sur des questions fermées dont la réponse est un score (e.g. entre 1 et 10) ou un "Oui"/"Non". Ce format présente l'avantage d'être simple et très rapide à traiter et analyser. Cependant, les questions fermées présentent des limites évidentes. Prenons l'exemple de la question "Êtes-vous en accord avec la politique actuelle du gouvernement sur l'environnement?". Avec une simple réponse binaire "Oui"/"Non", des individus aux opinions différentes pourraient donner la même réponse, alors que l'un pense que le gouvernement en fait trop sur la législation des pesticides, qu'un autre pense qu'il devrait en faire plus pour le contrôle des gaz à effet de serre, ou qu'un troisième pense qu'il devrait mieux aider lors des rénovations énergétiques. Ainsi, tous se diront en désaccord avec la politique du gouvernement en matière d'environnement, mais pour des raisons très différentes dont le détail est perdu à cause de l'utilisation d'une question fermée.

Face à ce problème apparaît alors la solution des questions ouvertes. En permettant aux contributeurs de s'exprimer librement et de mieux détailler leur point de vue, elles offrent aux commanditaires un aperçu plus riche des opinions exprimées et de la réalité du terrain, et peuvent ainsi favoriser une prise de décision plus adéquate. Elles permettent également de mieux nuancer les réponses, ce qui peut contribuer à dépasser les idées préconçues ou bénéficiant le plus de visibilité dans les médias. Enfin, lorsque les consultations publiques sont perçues comme sincères et suivies d'effets concrets, elles peuvent renforcer le sentiment que la participation individuelle a une influence réel sur les décisions publiques. Ce dernier point est d'autant plus crucial dans un contexte marqué par une abstention électorale élevée et une défiance croissante à l'égard des institutions [AB22, BCR26].

Deux initiatives de consultations publiques à grande échelle ont récemment été menées en France : le Grand Débat National et la Convention Citoyenne pour le Climat, organisées entre 2019 et 2020. Toutes deux avaient pour objectif, aux travers de questions ouvertes, de mieux capter l'opinion des citoyens français, notamment en réaction au mouvement des gilets jaunes de 2018 [BM19]. Ces deux consultations ont toutefois représenté un coût important : 12 millions d'euros et environ 2 millions de contributeurs pour la première, 5,4 millions d'euros et 150 participants pour la seconde [BM19, Cou20]. Ces chiffres mettent en évidence une des limitations majeures de l'utilisation des questions ouvertes : elles nécessitent un investissement matériel et humain conséquent afin d'assurer la diffusion de l'information, le recueil des contributions et leur analyse. La démocratie participative a donc un coût qui peut rapidement devenir élevé lorsqu'on souhaite organiser des dispositifs à grande échelle. Une autre problématique de ce type



FIGURE 1 – Logo de la Convention Citoyenne pour le Climat

de consultations concerne leur temporalité. Pour qu’une consultation reste pertinente, le recueil et le traitement des avis doivent être réalisés dans un délai raisonnable. Si l’analyse est trop longue, il peut devenir difficile d’agir efficacement (e.g. la fin du mandat du commanditaire), les problématiques soulevées peuvent avoir évolué et des résultats tardifs peuvent fragiliser la confiance entre les participants et les institutions à l’origine de la démarche.

L’analyse manuelle de consultations publiques ouvertes fait donc face à plusieurs défis majeurs : elle est lente, coûteuse et reste sujette aux biais humains. Les outils numériques, et notamment les grands modèles de langues (*Large Language Models*, LLM), constituent une piste de réponse intéressante face à ces contraintes. En effet, ils peuvent automatiser certaines étapes de l’analyse, identifier les idées récurrentes au sein d’un grand nombre de contributions, produire des synthèses thématiques, favoriser une analyse plus transparente et reproductible, et réduire significativement le délai entre la collecte des contributions et la production du rapport final. Bien entendu, l’utilisation d’outils numériques dans le cadre des décisions publiques ne vise pas à remplacer la décision humaine ni à déléguer l’ensemble du processus décisionnel à une intelligence artificielle. Néanmoins, les processus démocratiques et la digitalisation ne sont pas incompatibles, et les associer pourraient contribuer à réduire les contraintes logistiques et administratives inhérentes à l’organisation de consultations à grande échelle. Plusieurs initiatives vont déjà dans ce sens, et nous pouvons notamment en citer deux :

- Le projet ouvert *Plurality*, qui promeut le développement de technologies collaboratives et décentralisées visant à renforcer la participation démocratique, la délibération collective et la protection des droits numériques [WTC26].
- L’outil open source *Talk To The City* d’Objectives AI , qui mobilise des méthodes de traitement automatique du langage pour analyser à grande échelle les contributions citoyennes et structurer les opinions exprimées lors de consultations publiques [Ins26].

1.2 Objectif des travaux




FIGURE 2 – Pipeline globale du projet Perspectiva

Perspectiva, le projet développé par Data4Good et dans lequel s’inscrivent nos travaux, se trouve dans la continuité de cette démarche. Il utilise les outils numériques dans le but d’analyser et de mieux comprendre ce qu’un large groupe de personnes peut penser [Cyr]. Il se décline actuellement en deux phases principales : i) l’extraction et l’analyse (type, syntaxe et sémantique) d’idées issues de contributions d’individus à une consultation via un LLM, et ii) le regroupement de ces dites idées en méta-idées plus larges via l’utilisation d’algorithmes de clustering (STS, UMAP20, HDBSCAN, etc.) (Figure 2).

En théorie, ce protocole permet de résumer de manière assez exhaustive les thèmes principaux exprimés dans un grand nombre de contributions.

Bien que très puissants, les LLM ne sont cependant pas exempts de défauts. Nous observons parfois des hallucinations où la sortie du LLM contient des informations non présentes dans la contribution d'origine, voire fausses. À l'inverse, certaines idées exprimées sont parfois omises ou fragmentées en plusieurs morceaux sans aucun sens. Ce type d'erreurs, qui survient dans la première phase du projet, peut entraîner un certain nombre de problèmes par la suite. Des idées non exprimées pourraient se retrouver dans les méta-idées finales ou, à l'inverse, des idées intéressantes pourraient être perdues à cette étape. Cela conduirait alors à des interprétations erronées et à un bilan final de la consultation peu représentatif des opinions réelles de la population consultée. Ainsi, une problématique majeure de *Perspectiva* est de pouvoir mesurer la qualité des extractions réalisées avec le LLM durant la première phase.

Notre projet tutoré s'est donc articulé autour de trois dimensions : i) l'évaluation de la capacité de métriques à détecter et quantifier la qualité des extractions issues de LLM, puis ii) la réalisation d'un pipeline de traitement afin de réaliser cette évaluation de façon systématique pour plusieurs modèles de LLM, et iii) l'influence du choix du LLM d'extraction sur la qualité du rendu (tant sur les extraction que sur les résultats du pipeline construit).

La suite de ce rapport constitue une synthèse de nos travaux, organisée en trois parties : i) présentation des données utilisées, des méthodes mises en place et des métriques étudiées, ii) nos résultats d'extractions, de validation des métriques et d'influence du LLM choisi, et iii) une réflexion sur les enjeux environnementaux et sociétaux de ce projet à différentes échelles.

2 Données et Méthodes

2.1 Organisation et gestion de projet

Ce projet a été réalisé sous la supervision de Cyril François, l'un des membres à l'origine du projet *Perspectiva*. Nous avons travaillé en interaction régulière avec lui via des réunions d'avancement et un tableau Kanban qui ont permis de structurer les tâches, de prioriser les objectifs et de suivre l'état d'avancement du projet. En complément de ces échanges, nous avons également organisé des points hebdomadaires entre membres du groupe afin de faire un état des lieux de l'avancement et d'ajuster la répartition des tâches de manière coordonnée.

L'ensemble du travail (code, scripts d'analyse, documentation et résultats intermédiaires) est accessible sur le [GitHub du projet tutoré](#), dans une logique de transparence et de reproductibilité.

Tous les traitements et analyses ont été réalisés sous Visual Studio Code (v1.109.3) avec Python (v3.13.12). Les principales bibliothèques mobilisées sont : numpy (v2.3.3), ollama (v0.6.0), pandas (v2.3.3), plotly (v6.3.1), requests (v2.32.5), rouge_score (v0.1.2), sentence-transformers (v5.2.2), torch (v2.9.0), tqdm (v4.67.1), transformers (v4.57.1), google (3.0.0) et google-genai (1.64.0). Ces outils ont été utilisés pour le traitement des contributions, l'extraction via des modèles de langue, l'évaluation des sorties et la visualisation des résultats.

2.2 Données

Afin de mener notre analyse de validation de différentes métriques, il était nécessaire de travailler sur un corpus de texte réaliste. Nous avons fait le choix de travailler sur des données issues d'une consul-

tation publique réelle, plutôt que sur des textes artificiellement construits ou excessivement "lissés". En effet, des textes trop homogènes, normés, "parfaits", auraient peu reflété la réalité de la diversité stylistique, lexicale, grammaticale et orthographique observée dans de véritables contributions citoyennes, ce qui aurait limité la capacité de généralisation de nos résultats.

Nous avons ainsi retenu les réponses à la question n°163 du Grand Débat National : " *Que faudrait-il faire pour rendre la fiscalité plus juste et plus efficace ?* ", intégrée au thème portant sur la fiscalité. Les contributions sont rédigées en texte libre, sans limite de caractères. Elles n'ont fait l'objet d'aucune modification préalable : les erreurs de syntaxe, de grammaire ou d'orthographe ont été conservées afin de maintenir des conditions d'analyse proche d'une véritable contexte.

Les données utilisées sont accessibles publiquement sur la plateforme gouvernementale [data.gouv](https://data.gouv.fr), et notamment via le lien dédié au jeu de données utilisé ici. L'ensemble des jeux de données du Grand Débat National sont disponibles sur cette même plateforme, de même que d'autres consultations publiques similaires. Les contributions sont entièrement anonymisées et conformes aux exigences du RGPD, garantissant le respect de la protection des données personnelles.

Taxer davantage les très très riches....On m'a augmenté ma CSG pour la donner à Mr Bernard Arnaud ou à Mr Goshn, cet argent que l'on m'a volé, on l'a volé à mes enfants et petits enfants que je suis obligé d'aider à démarrer dans ma vie, on l'a volé à mes parents âgés car je sois les aider à payer toujours plus, un établissement de retraite décent !!

Contribution n°75

Surtout ne pas rétablir l'ISF, qui nous fait perdre 35 milliards (Monsieur Edouard Philippe le 09 octobre 2017) et qui fait de la France un des seuls pays au monde à posséder encore un tel impôt (IFI). Assez de démagogie

Contribution n°178

Qu'elle frappe en priorité les TRES RICHES : ISF, FLAT TAXE.....TAXER l'EVASION FISCALESupprimer toutes les niches fiscales inefficaces et coûteuses

Contribution n°163

FIGURE 3 – Exemples de contributions

Pour la question étudiée, 154000 contributions sont disponibles (sur environ 186000 participations sur le thème de la fiscalité). Néanmoins, pour des raisons de coûts temporels, computationnels et financiers, notamment liés à l'annotation humaine et aux traitements automatiques, nous avons restreint notre analyse à un sous-échantillon de 200 contributions. Nous avons retenu les 200 premières entrées du corpus, puis vérifié qu'elles présentaient des caractéristiques globales cohérentes avec l'ensemble du jeu de données, de manière à garantir la représentativité.

La distribution des longueurs de texte étant très déséquilibrée (Figure 4a), nous avons choisi de construire 4 classes arbitraires afin de trier les contributions : très court (<50 tokens), court (51-100 tokens), moyen (101-200 tokens) et long (>200 tokens) (Figure 4b), afin de pouvoir observer, par la suite, si la taille de la contribution avait une influence sur la présence d'hallucinations, d'idées séparées ou sur la validité des métriques.




FIGURE 4 – Analyse descriptive des longueurs des 200 premières contributions

2.3 Protocole d'extraction et d'évaluation

Afin de pouvoir correctement analyser et comparer les différentes métriques sélectionnées, nous avons mis en place un protocole reproductible pour chacune d'entre elles, basé sur la comparaison entre la notation de la métrique avec une notation humaine des extractions d'idées réalisées par le LLM [Rei25]. Nous avons donc procédé comme suit :

1. Extraction des idées de chaque contribution via un LLM.
2. Calcul de la métrique sélectionnée (QualIT, ROUGE, NLI détaillées dans la section suivante) sur chaque extraction.
3. Notation manuelle de l'extraction :
 - a. Chacun des trois membres du groupe note chaque extraction. Pour prévenir au maximum de biais éventuels dû à une notation humaine, nous avons fixé au préalable un ensemble de règles (Encadré 1).
 - b. Marquage de la présence d'hallucinations. Cette notion correspond aux contributions pour lesquelles le LLM a inventé certaines idées (Figure 6).
 - c. Marquage de la présence d'idées séparées. Cette notion correspond aux contributions pour lesquelles le LLM a découpé une idée sans prendre en compte le sens (Figure 7).
4. Calcul des corrélations entre chaque annotateur pour vérifier leur accord.
5. Agrégation des notes humaines en un "score humain" correspondant à la moyenne des trois notes humaines puis ramené entre 0 et 1.
6. Calcul de la corrélation entre le score humain et la métrique sélectionnée.

1. La note doit être comprise entre 0 et 10. Plus la note est élevée, plus l'extraction est de qualité.
2. L'extraction doit contenir le même nombre d'idées que la contribution originelle. Aucune idée ne doit être ni ajoutée, ni omise.
3. Les idées extraites doivent garder le même sens que l'idée originale (e.g. une idée négative doit le rester).
4. Les idées extraites doivent être distinctes. Il ne doit pas y avoir de redondance.
5. L'extraction doit être en français.

Encadré 1 – Règles de notation

L'objectif de cette première phase d'analyse n'était pas d'optimiser les performances d'extraction, mais au contraire d'explicitement obtenir des erreurs (hallucinations, fragmentations des idées, déformations sémantiques, etc.) afin d'évaluer la capacité des métriques étudiées à détecter et quantifier les différents types de défaillances dans l'extraction.

Ainsi, nous avons fait le choix dans cette première partie d'utiliser un "petit" modèle de langue : `llama3:8b-instruct-q4_K_M`, exécuté en local via `ollama`, avec une `temperature` fixée à 0 afin de garantir la reproductibilité des sorties, et un paramètre `top_p` réglé à 0.95 (valeur standard). Ce choix a reposé sur un compromis méthodologique et computationnel. Un modèle de 8 milliards de paramètres est suffisamment complet pour comprendre des consignes complètes et produire une sortie au format imposé tout en évitant que la majorité des sorties soient de mauvaise qualité. Nous avons aussi été contraints par nos machines et un accès *limité* à de plus gros serveurs de calcul pour le choix du LLM.

Pareillement, Dans la continuité de cette absence de recherche de performance, nous avons choisi un prompt très proche de celui employé initialement par le projet Perspectiva (Annexe – Figure 32). Bien que l'analyse de sentiments (type de phrase, syntaxe et sémantique) ne fasse pas l'objet d'une exploitation dans la suite de ce rapport, nous avons choisi de la conserver dans le prompt afin d'assurer la compatibilité et l'intégrabilité directe de notre travail dans l'architecture globale du projet Perspectiva.

2.4 Métriques

Une métrique d'évaluation est une fonction associant un score à une production textuelle afin de mesurer une propriété donnée. Dans notre cas, l'objectif était d'évaluer la qualité d'une extraction produite par un LLM, c'est-à-dire d'estimer dans quelle mesure les idées extraites restituaient fidèlement les idées contenues dans la contribution d'origine. Toutefois, la notion de qualité est polysémique et peut recouvrir beaucoup de notions très diverses. Une extraction peut être vue de mauvaise qualité, car elle n'a pas su synthétiser les idées principales et a conservé trop d'exemples non pertinents, comme une métrique peut être de mauvaise qualité à cause de l'omission de certaines sous-idées. De la même façon, toutes les métriques ne mesurent pas les mêmes dimensions. Certaines reposent principalement sur le chevauchement lexical entre deux textes (n-grammes communs, recouvrement de tokens), tandis que d'autres cherchent à capturer leur proximité sémantique (proximité de leurs emmbedings). Ainsi, une extraction peut obtenir un score élevé selon une métrique fondée sur le recouvrement lexical tout en présentant des défauts notables du point de vue de la cohérence sémantique, des informations contenues et inversement.

Dans ce contexte, nous avons étudié plusieurs métriques reposant sur des fondements méthodologiques distincts afin d’analyser leur capacité à détecter différents types d’erreurs (hallucinations, omissions, fragmentation d’idées, déformations sémantiques, etc.) et leur capacité à être complémentaire dans une perspective d’un usage conjoint dans un pipeline. Nous avons présenté ici les trois familles de métriques retenues – QualIT, les métriques ROUGE et les métriques NLI –, chacune correspondant à une approche spécifique de l’évaluation de la qualité d’une extraction.

Métrique QualIT

La première métrique que nous avons étudiée est issue du travail présenté dans le papier *Qualitative Insights Tool (QualIT) : LLM Enhanced Topic Modeling* [KGB⁺24]. Bien que QualIT soit initialement conçu comme un outil de topic modeling intégrant des modèles de langue, il propose également un mécanisme permettant d’évaluer la cohérence globale des éléments extraits par un LLM. Cette propriété en a fait une métrique candidate pour nos analyses, notamment en tant que métrique basée sur une proximité sémantique.

Dans l’approche décrite par les auteurs, l’ensemble des idées extraites d’une contribution est concaténé en un unique texte. La contribution originale et cette concaténation sont ensuite projetées dans un espace d’embeddings (via `sentence-transformers/all-MiniLM-L6-v2` produisant des embeddings de dimension 384). On obtient ainsi deux vecteurs de dimension fixe, représentant respectivement le texte original et l’extraction agrégée. La similarité entre ces deux représentations est ensuite calculée à l’aide d’une similarité cosinus (voir ci-après), ce qui permet d’obtenir un score unique pour chaque contribution. Ce score vise à quantifier la proximité sémantique globale entre le texte initial et l’ensemble des idées extraites, indépendamment du chevauchement lexical exact.

$$C_i = \frac{1}{n} \sum_{j=1}^n \frac{V_{inp,ij} \cdot V_{key,ij}}{|V_{inp,ij}| \cdot |V_{key,ij}|}, \text{ avec } \begin{cases} C_i & \text{le score QualIT de la } i^e \text{ contribution.} \\ n & \text{la dimension de l'espace d'embedding.} \\ V_{inp,ij} & \text{la } j^e \text{ coordonnée du vecteur d'embedding de la} \\ & i^e \text{ contribution.} \\ V_{key,ij} & \text{la } j^e \text{ coordonnée du vecteur d'embedding des idées} \\ & \text{extraites de la } i^e \text{ contribution.} \\ |\cdot| & \text{une norme euclidienne.} \end{cases}$$

Un score élevé indique une forte proximité sémantique globale entre la contribution originale et l’ensemble des idées extraites, tandis qu’un score plus faible suggère une perte d’information, une déformation sémantique ou l’introduction d’éléments non alignés avec le texte source.

Métrique ROUGE

La seconde famille de métriques évaluée est ROUGE (Recall-Oriented Understudy for Gisting Evaluation) [Lin04a]. ROUGE regroupe un ensemble d’indicateurs initialement développés pour l’évaluation automatique de résumés, en comparant un texte généré à un texte de référence à partir de leur recouvrement lexical. Le principe sous-jacent est le suivant : si une extraction est fidèle à la contribution originale, alors une proportion significative des unités lexicales (mots, n-grammes, séquences) présentes dans le texte d’origine devrait également apparaître dans le texte extrait. ROUGE traduit cette idée en mesurant le chevauchement entre les deux textes selon différentes granularités

(par exemple, unigrammes pour ROUGE-1, ou plus longues séquences communes pour ROUGE-L).

Dans notre contexte, l'extraction produite par le LLM (ensemble des idées extraites) est considérée comme le texte généré, tandis que la contribution originale joue le rôle de référence. ROUGE permet ainsi de quantifier dans quelle mesure le contenu lexical de l'extraction recouvre celui du texte source. Cette approche est donc, *a priori*, pertinente pour détecter des omissions importantes, les hallucinations ou un appauvrissement lexical, mais elle reste principalement sensible à la surface textuelle et ne capture pas systématiquement les reformulations restant sémantiquement équivalentes.

Ainsi, la métrique ROUGE se décline en plusieurs variantes, correspondant à différentes manières de comparer deux textes :

- **ROUGE-N** : mesure le chevauchement de n -grammes (séquences de n mots) entre la référence et le texte généré. Dans notre cas, nous utilisons $n = 1$ (ROUGE-1), ce qui revient à comparer le recouvrement en unigrammes.
- **ROUGE-L** : se base sur la *plus longue sous-séquence commune* (*Longest Common Subsequence*, LCS), ce qui permet de capturer une similarité en séquence sans imposer que les mots soient strictement consécutifs.
- **ROUGE-S / ROUGE-SU** : repose sur des *skip-bigrammes*, c'est-à-dire des paires de mots apparaissant dans le même ordre, possiblement séparés par d'autres mots (avec ou sans unigrammes).

Les scores ROUGE sont compris entre 0 et 1. Un score proche de 1 indique une forte similarité entre les deux textes, tandis qu'un score proche de 0 suggère une faible similarité. Dans ce projet, notre objectif n'était pas d'évaluer une correspondance strictement *mot-à-mot*, puisqu'une extraction de qualité peut reformuler le texte original tout en en conservant le sens. Néanmoins, ROUGE constitue une approche pertinente : elle est simple à implémenter, rapide à calculer et largement utilisée dans la littérature, ce qui facilite l'interprétation et la comparaison des résultats. Ces propriétés en ont fait une bonne métrique candidate pour nos analyses, notamment en combinaison avec la métrique QualIT.

Nous avons retenu deux variantes : ROUGE-1 et ROUGE-L. L'implémentation repose sur la librairie `rouge_score` en Python. Pour chaque contribution, nous avons comparé le texte original (`contribution`) au texte d'extraction agrégé (`ideas_text`). Nous avons conservé la mesure F_1 (désignée comme *F-measure* dans la librairie), qui combine précision et rappel et permet de limiter certains effets liés aux différences de longueur entre les textes [Lin04b]. En cas d'erreur de parsing (extraction vide, format non conforme), nous avons attribué un score nul afin d'éviter toute surestimation artificielle des performances.

Métrique NLI

La troisième métrique étudiée repose sur le cadre du *Natural Language Inference* (NLI). Elle s'inscrit dans les travaux en inférence textuelle dont l'objectif est de déterminer, à partir d'une prémisse p et d'une hypothèse h , la relation inférentielle qui les relie. La prémisse p constitue le texte de référence, décrivant une situation et un ensemble d'informations supposées vraies pour les besoins de l'évaluation, tandis que l'hypothèse h est un second énoncé dont on cherche à établir le statut relativement à p .

Trois relations sont classiquement distinguées (Figure 5) :

- **Entailment (E)** : l'hypothèse h est entraînée par p , c'est-à-dire que dans toute situation compatible avec p , h est également vraie.
- **Contradiction (C)** : l'hypothèse h est incompatible avec p ; si p est vraie, alors h doit être fausse.
- **Neutral (N)** : l'hypothèse h n'est ni entraînée ni contredite par p ; la vérité de h reste indéterminée relativement à p .




FIGURE 5 – Exemple des relations NLI

Dans l'analyse proposée par Blanck, Noble et Chatzikyriakidis [BNC26], ces relations ne doivent pas être comprises comme de simples catégories empiriques, mais comme de véritables relations d'inférence dont l'interprétation dépend du cadre logique adopté (conditionnelle matérielle, conditionnelle stricte modale, lecture avec import existentiel, etc.). Ainsi, la distinction entre *entailment*, *contradiction* et *neutral* repose sur des critères sémantiques précis et non uniquement sur une similarité lexicale. Deux phrases peuvent partager de nombreux mots sans entretenir de relation d'entailment, tandis qu'une paraphrase peut être logiquement équivalente malgré un faible recouvrement lexical. Autrement dit, il ne s'agit pas uniquement d'évaluer si les deux textes "se ressemblent", mais aussi de déterminer si l'un implique logiquement l'autre.

Les propriétés du cadre NLI sont donc pertinentes dans notre contexte, où nous cherchions à vérifier si les idées extraites par le LLM sont bien soutenues par la contribution originale, et à pénaliser les cas où le LLM inversait le sens (par exemple via une négation) ou introduisait des éléments qui n'étaient pas présents. L'enjeu est d'évaluer la fidélité sémantique d'une extraction, indépendamment des variations de surface textuelle.

La tâche NLI peut être vue comme l'apprentissage d'une fonction qui associe à chaque paire d'énoncés une relation inférentielle :

$$f : (p, h) \mapsto \{E, C, N\}.$$

Dans l'idéal, cette classification est réalisée à l'aide d'un NLI entraîné spécifiquement pour la tâche considérée. Afin d'éviter l'entraînement local d'un réseau de neurones, une opération coûteuse en temps de calcul et en ressources matérielles, nous avons fait le choix d'utiliser un modèle NLI pré-entraîné de référence. Plus précisément, nous avons retenu le modèle `ynie/roberta-large-snli_mnli_fever_anli_R1_R2_R3-nli`, disponible sur la plateforme Hugging Face, entraîné sur plusieurs corpus standards de NLI (SNLI, MNLI, FEVER et ANLI).

Néanmoins, notre démarche initiale a consisté à reproduire l'intuition sous-jacente au NLI sans recourir à un réseau de neurones. Nous avons donc implémenté une approximation de cette intuition, que nous avons ensuite comparée au réseau de neurones pré-entraîné.

Cette implémentation repose sur la combinaison de deux mesures complémentaires de similarité textuelle : un score de Jaccard, qui capture le recouvrement lexical entre la contribution et l'extraction, et une mesure LCS, qui tient compte de l'ordre relatif des termes. La première reflète la proximité de contenu, tandis que la seconde permet de préserver une cohérence séquentielle. Cette combinaison se justifie notamment par la formalisation de la composante LCS qui vise à approximer une relation d'entailment par des indices de similarité de surface [Lin04a].

Nous avons donc implémenté une approximation lexicale de type NLI, en respectant l'idée suivante : une idée extraite est d'autant plus fiable qu'elle présente une forte similarité avec au moins une phrase de la contribution, et qu'elle ne contredit pas cette phrase.

Calcul du score de support. Nous découpons d'abord la contribution en phrases $\{p_j\}$ (ponctuation forte et retours à la ligne) qui correspondront aux prémisses, et nous considérons les idées extraites $\{h_i\}$ obtenues par le LLM comme les hypothèses. Pour chaque idée h_i , nous calculons un score de similarité avec chacune des phrases p_j et nous conservons le meilleur appariement :

$$\text{support}(h_i) = \max_j (0.6 \cdot J(h_i, p_j) + 0.4 \cdot \text{LCS}(h_i, p_j)),$$

Le score de Jaccard $J(h_i, p_j)$ est défini comme :

$$J(h_i, p_j) = \frac{|T(h_i) \cap T(p_j)|}{|T(h_i) \cup T(p_j)|},$$

où $T(\cdot)$ désigne l'ensemble des tokens du contenu (après suppression d'une liste minimale de mots-outils). Ce score mesure le recouvrement lexical entre les deux ensembles. La composante $\text{LCS}(h_i, p_j)$ correspond à un ratio basé sur la *longest common subsequence* (plus longue sous-séquence commune), qui capture une similarité séquentielle en tenant compte de l'ordre relatif des mots. Elle est ici implémentée via la classe `SequenceMatcher` de la bibliothèque standard Python.

Le score final $\text{support}(h_i)$ est compris entre 0 et 1. Plus il est élevé, plus l'idée h_i est lexicalement proche d'au moins une phrase de la contribution.

Pénalisation des contradictions par négation. Afin de détecter une éventuelle inversion de polarité (mots similaires mais sens inversé), nous introduisons une fonction booléenne $\text{neg}(\cdot)$ qui détecte la présence d’un marqueur explicite de négation : " ne ", " n’ ", " pas ", etc.

Nous définissons $j^* = \arg \max_j (0.6 \cdot J(h_i, p_j) + 0.4 \cdot LCS(h_i, p_j))$, c’est-à-dire l’indice de la phrase présentant le support maximal. On note alors p_{j^*} la phrase la plus similaire à h_i .

Si la polarité diffère entre h_i et p_{j^*} , nous appliquons une pénalité :

$$\text{contra}(h_i) = \mathbf{1} [\text{neg}(h_i) \neq \text{neg}(p_{j^*})] \cdot (1 - \text{support}(h_i)) \cdot \alpha,$$

où $\alpha \in [0, 1]$ est un facteur de pénalisation. Nous avons fixé $\alpha = 0.8$ dans nos expériences, cette valeur a été retenue sur la base des résultats obtenus lors de nos expérimentations, dans le but d’assurer un compromis entre détection des contradictions et cohérence du score final.

Si une idée est peu supportée par le texte et qu’elle inverse la polarité via une négation, il est probable qu’elle corresponde à une hallucination ou à une mauvaise reformulation. Ainsi, en théorie, cette approximation lexicale de type NLI devrait pouvoir détecter avec aisance les hallucinations d’un LLM.

Score final. L’objectif de cette métrique NLI est de maximiser l’entailment tout en minimisant la contradiction de l’extraction. Toutefois, dans un contexte d’évaluation automatique, ces deux indicateurs ne sont pas nécessairement symétriques. Une idée peut être faiblement soutenue sans pour autant être contradictoire (cas neutre), tandis qu’une contradiction explicite constitue une indication forte de mauvaise qualité d’extraction d’idée. Pour cette raison, nous avons construit un score final regroupant ces deux aspects.

Pour chaque contribution p , nous agrégeons ensuite les scores sur l’ensemble des idées extraites $\{h_1, \dots, h_n\}$. Nous calculons :

$$NLI_{\text{support}}(p) = \frac{1}{n} \sum_{i=1}^n \text{support}(h_i)$$

$$NLI_{\text{contra}}(p) = \frac{1}{n} \sum_{i=1}^n \text{contra}(h_i)$$

$$NLI_{\text{final}}(p) : \max [0, \min [1, NLI_{\text{support}}(p) - NLI_{\text{contra}}(p)]]$$

Ce score final est compris entre 0 et 1. Un score élevé correspond à des idées globalement bien supportées par la contribution et ne présentant pas d’inversion évidente du sens via la négation.

Il convient néanmoins de souligner que cette approximation NLI présente plusieurs limitations. Elle nécessite que la contribution puisse être bien découpée en phrases $\{p_j\}$ et que chaque idée soit comprise dans une seule phrase. De plus, elle ne capture ni les inférences pragmatiques, ni les reformulations sémantiques profondes, ni les phénomènes de paraphrase complexe.

2.5 Pipeline

Afin de permettre une réutilisation complète et rapide de nos travaux, nous avons construit un pipeline de traitement des contributions. À partir d’un LLM et d’un prompt donné, ce pipeline

permet d’extraire les idées contenues dans chaque contribution, de réaliser l’analyse de sentiments, puis de retourner un jeu de données structuré et concaténé pour chaque contribution. Ce pipeline intègre également le calcul des différentes métriques présentées précédemment. Il permet de produire soit un jeu de données brut (incluant l’ensemble des extractions), soit un jeu filtré, dans lequel les contributions associées à des extractions jugées de faible qualité, selon des seuils définis sur les scores des métriques, sont exclues. L’ensemble du processus, depuis l’appel au modèle jusqu’à la mise en forme des sorties, est ainsi intégré dans une unique chaîne de traitement.

Au-delà de cet aspect opérationnel, le pipeline a pour objectif de combiner l’effet des différentes métriques analysées. Comme discuté précédemment, ces métriques mesurent des propriétés distinctes (recouvrement lexical, proximité sémantique globale, etc.). Leur agrégation permettait ainsi d’obtenir une évaluation plus robuste et plus nuancée de la qualité d’une extraction qu’une métrique seule. Cette approche vise ainsi à obtenir l’évaluation la plus complète possible des idées extraites par rapport au texte source.

2.6 Influence du LLM d’extraction

Comme indiqué en introduction, notre analyse n’a pas porté uniquement sur la pertinence intrinsèque des métriques, mais également sur l’influence du modèle d’extraction choisi. L’objectif était double. D’une part, il s’agissait d’évaluer empiriquement si l’utilisation d’un modèle de plus grande capacité permettait effectivement d’obtenir des extractions de meilleure qualité qu’un modèle plus léger et généraliste. D’autre part, nous cherchions à vérifier si les métriques étudiées, et plus largement le pipeline qui les agrège, étaient sensibles à cette différence de qualité, c’est-à-dire si elles attribuaient effectivement de meilleurs scores aux extractions produites par un modèle plus performant.

Pour cela, nous avons reproduit le protocole d’évaluation en remplaçant le modèle d’extraction initial par un modèle de plus grande taille. Les 200 contributions sélectionnées ont été soumises à une nouvelle extraction, puis celles-ci ont été annotées manuellement (score, hallucinations, idées séparées). Afin de réduire les coûts temporels, une seule personne a réalisé cette seconde annotation. Nous avons fait ce choix suite au constat d’un fort accord entre les annotateurs lors de la phase d’évaluation avec le premier modèle (Cf section suivante). Les extractions obtenues ont ensuite été évaluées selon le même protocole que précédemment : application du score QualIT, calcul des métriques ROUGE et évaluation par NLI (à la fois via notre approximation lexicale et via le modèle pré-entraîné).

Le modèle utilisé pour cette seconde extraction était **Gemini 3 Pro** (version preview), un modèle de grande taille. Nous avons pu accéder à ce modèle via le compte *Vertex AI* (Google) de notre tuteur et dont l’utilisation est payante, ce qui introduit une contrainte budgétaire non négligeable. L’intégration a été réalisée en Python à l’aide des bibliothèques `genai` et `google.oauth2`.

3 Résultats et discussion

3.1 Extractions et notation humaine

Comme énoncé précédemment, nous avons travaillé sur les 200 premières contributions non vides parmi celles disponibles dans les données relatives à la question n°163 du Grand Débat National.

Un certain nombre de ces extractions présentaient des problèmes. Nous avons notamment identifié deux grandes classes d'erreurs :

1. Le LLM hallucinait, c'est-à-dire qu'il inventait des idées non présentes dans la contribution originale, mais dont le sens découlait généralement d'autres idées bien présentes (Figure 6).
2. Le LLM découpait une idée ou une phrase de manière plus ou moins incohérente. Cette situation arrivait notamment en présence de pronom ou de conjonction de coordination ; la phrase est séparée en deux mais les idées extraites ne peuvent pas être comprises indépendamment (Figure 7).




FIGURE 6 – Exemple d'hallucination du LLM




FIGURE 7 – Exemple d'idées séparées par le LLM

Ces deux cas de figure étaient typiquement le genre d'erreurs que nous souhaitions qu'une bonne métrique soit en mesure de détecter. Nous avons donc pris soin de bien marquer leur présence lors de la notation humaine.

Par un calcul de corrélation, nous avons donc vérifié notre accord, et nous étions généralement tous en accord (corrélation > 0.9 à chaque fois) (Table 1). Nous avons donc agrégé les trois notes via une moyenne standard. Nous obtenons finalement un "score humain" moyen d'environ 0.54, avec une médiane à 0.6, un minimum à 0 et un maximum à 1 (Annexe - Figure 33).

	Garance	Matthias
Garance		0.93
Yannis	0.93	0.94

TABLE 1 – Corrélacion des notes entre annotateurs du groupe

En analysant le score humain moyen dans chaque catégorie de longueur de contribution, nous avons observé une dégradation de qualité pour les *longues* contributions. Ce constat était d’autant plus surprenant sachant que nous observions initialement une amélioration du score moyen des très courtes aux moyennes contributions (Figure 8).






FIGURE 8 – Score humain moyen selon la catégorie de longueur

Nous avons observé un taux d’hallucination assez élevé pour les très courtes et courtes contributions (> 0.4 et > 0.2 resp.) (Figure 9a). Dans les faits, nous avons surtout observé que pour les courtes contributions, le LLM avaient tendance à ajouter plusieurs idées très proches, qu’on pourrait aisément attribuer à un individu ayant écrit la contribution considérée. Cet effet semble s’estomper pour les contributions plus longues. À l’inverse, nous avons relevé que les contributions très courtes étaient légèrement moins touchées par les idées séparées (ou invalides) que les contributions plus longues (Figure 9b). Ceci peut sans doute s’expliquer par le fait que les contributions très courtes soient simplement trop courtes pour être séparables.




(a) Taux d’hallucinations selon la catégorie de longueur




(b) Taux d’idées séparées selon la catégorie de longueur

FIGURE 9 – Analyse descriptive des longueurs des 200 premières contributions

Enfin, nous avons cherché à déterminer à quel point le score humain était influencé par la présence d'hallucinations ou d'idées séparées. Nous avons pu observer une différence beaucoup plus nette du score humain moyen selon la présence d'hallucinations (0.75 contre 0.28 en présence d'hallucinations) par rapport à l'influence de la présence de séparation d'idées (0.6 contre 0.5 en présence d'idées séparées) (Figures 10a et 10b). Il semble donc que la présence d'idées séparées dans l'extraction est moins de répercussions sur sa qualité que la présence d'hallucinations.



(a) Score humain moyen selon la présence d'hallucinations



(b) Score humain moyen selon la présence d'idées séparées

FIGURE 10 – Variation du score humain moyen selon la présence d'hallucinations ou d'idées séparées

3.2 Métrique QualIT

Résultats généraux

À première vue, la métrique QualIT et le score humain nous ont semblé être plutôt en accord : nous avons relevé une corrélation de Pearson de 0.71 et une corrélation de Spearman de 0.72 entre les deux.




FIGURE 11 – Score humain selon le score QualIT

Cependant, nous avons obtenu une différence notable de score moyen entre la métrique QualIT (0.78) et le score humain (0.54), qui suggère donc a priori une surnotation par QualIT. Cette impression a ensuite été confirmée en regardant plus en détail les scores de la métrique selon les scores humains. Nous avons une très grande masse d'extractions qui sont très bien notées par la métrique QualIT malgré un score humain moyen ou faible, alors que le cas de figure inverse n'a pas été observé (Figure 11).

Influence de la longueur de la contribution

L'analyse du score QualIT obtenu selon la longueur de la contribution à l'origine a montré des résultats similaires à ce que nous avons observé pour le score humain : les contributions courtes et moyennes

ont présenté, en moyenne, des scores QualIT plus élevés que les textes plus longs (score moyen de ~ 0.9 contre ~ 0.5) et également légèrement plus élevé que les textes très courts (~ 0.9 contre ~ 0.8) (Figure 12).





FIGURE 12 – Score QualIT moyen selon la longueur des contributions (en tokens)

Détection des hallucinations et des idées séparées



(a) Score humain selon le score QualIT, coloré selon la présence d'hallucinations



(b) Score humain selon le score QualIT, coloré selon la présence d'idées séparées

FIGURE 13 – Analyse descriptive des longueurs des 200 premières contributions

De manière assez logique, puisque la métrique QualIT tendait à surnoter la qualité des extractions, nous avons bien observé qu'elle ne parvenait pas bien à détecter les erreurs du type hallucinations ou idées séparées (Figure 13).

Cela peut en partie s'expliquer par le fonctionnement de la métrique QualIT : il repose sur la similarité entre le vecteur d'embeddings de la contribution originale et de toutes les idées extraites concaténées. Pour le cas des idées séparées, la présence d'un pronom ou d'une conjonction de coordination entraîne souvent la séparation de la phrase en plusieurs parties par le LLM, parties qui ne sont alors plus compréhensibles indépendamment. Ensuite, par l'action de concaténation, nous obtenons de nouveau un texte très similaire à la contribution de base, et donc à des embeddings très similaires, d'où un score QualIT relativement élevé (Figures 14 et 15).




FIGURE 14 – Exemple d’échec de détection d’idées séparées par QualIT, causé par la présence d’une conjonction de coordination




FIGURE 15 – Exemple d’échec de détection d’idées séparées par QualIT, causé par la présence d’un pronom

Concernant le phénomène d’hallucination, nous avons observé quelque chose d’assez similaire. Les idées hallucinées ajoutées à l’extraction forment, une fois concaténées, un texte dont l’embedding est assez proche de celui du texte original, ce qui aboutit à un score QualIT plutôt élevé (Figure 16).




FIGURE 16 – Exemple d’échec de détection d’hallucinations par QualIT

Ainsi, la métrique QualIT nous est apparue comme très imparfaite, avec un problème de surnotation et une incapacité à pouvoir réellement détecter les hallucinations et la présence d’idées séparées. Toutefois, elle a présenté une plutôt bonne corrélation avec le score humain moyen et elle a aussi l’avantage de se baser sur l’utilisation d’embeddings plutôt que la correspondance directe termes à termes. Nous avons donc considéré qu’elle pourrait être utile si couplée à une seconde métrique capable de détecter les hallucinations.

Métrique	Cor. P	Cor. S	Moy.	Méd.	Moy. (H*)	Moy. ($\neg$ H)	Moy. (I**)	Moy. ($\neg$ I)
QualIT	0.71	0.72	0.78	0.85	0.71	0.90	0.82	0.84

* H = contributions avec hallucinations

** I = présence d'idées séparées.

TABLE 2 – Synthèse quantitative de la métrique QualIT

3.3 Métrique ROUGE

3.3.1 Résultats ROUGE-L

Les scores ROUGE-L obtenus ont mis en avant une corrélation plutôt positive avec la notation humaine. Nous avons obtenu une corrélation de Pearson entre les scores ROUGE-L et la notation humaine de 0.78 et une corrélation de Spearman de 0.72, soit des résultats très similaires à ceux obtenus par la métrique QualIT.

Au global, nous avons observé une relation linéaire positive entre le score humain et le score ROUGE-L : les contributions ayant un score ROUGE-L élevé ont été majoritairement associées à des notes humaines élevées. Inversement, les extractions de faible qualité ont présenté généralement des scores ROUGE-L faibles, ce qui pourrait indiquer une certaine capacité à détecter les hallucinations qui sont souvent associées à des scores humains faibles. Néanmoins, nous avons également observé une dispersion notable autour de la droite $x = y$, notamment pour les scores intermédiaires (entre 0.2 et 0.8). Nous avons relevé la présence d'autant de sur-notations que de sous-notations, contrairement à la métrique QualIT où nous avons essentiellement observé une sur-notation (Figure 17). Ceci suggère que ROUGE-L capture efficacement le recouvrement séquentiel de surface, les extractions qui correspondent totalement ou pas du tout, mais ne permet pas toujours de distinguer des reformulations correctes de modifications sémantiques plus subtiles.




FIGURE 17 – Score humain selon le score ROUGE-L

Influence des hallucinations L'analyse en fonction de la présence d'hallucinations a confirmé notre intuition quant à la capacité de la métrique à "capturer" les hallucinations. Les contributions pour

lesquelles une hallucination avait été identifiée manuellement (en rouge sur la Figure 18) se concentraient majoritairement dans la zone correspondant à des scores ROUGE-L faibles et à des notes humaines basses. Bien sûr, nous n'avons pas observé une parfaite concordance entre la note humaine et la note fournie par la métrique pour l'ensemble des hallucinations, mais nous avons tout de même noté une amélioration nette par rapport à QualIT sur cette problématique. Cela signifie donc que ROUGE-L parvient à pénaliser les extractions comportant des hallucinations de manière relativement efficace.



FIGURE 18 – Score humain selon le score ROUGE-L, coloré selon la présence d'hallucinations

Influence de la longueur des contributions L'analyse par catégorie de longueur a mis également en évidence un effet notable de la taille des contributions. Les contributions courtes et moyennes ont présenté en moyenne des scores ROUGE-L plus élevés que les longues contributions (score moyen de 0.7 contre < 0.35), ce qui correspond aux résultats que nous avons pu observer précédemment pour le score humain et la métrique QualIT (Figure 19). Cet effet peut sans doute s'expliquer par le fait que, dans des textes plus longs, la probabilité d'omission partielle ou de fragmentation d'idées augmente, ce qui réduit mécaniquement le recouvrement séquentiel global.




FIGURE 19 – Score ROUGE-L moyen selon la longueur des contributions (en tokens)

Dans l'ensemble, ROUGE-L nous a donc semblé constituer une métrique pertinente pour détecter les erreurs "grossières" d'extraction et les hallucinations. Néanmoins, son caractère fondé sur la similarité

de surface limite sa capacité à capturer des écarts sémantiques plus subtils, ce que nous retrouvons généralement dans les contributions les plus longues (> 200 tokens).

3.3.2 Résultats ROUGE-1

Les scores ROUGE-1 ont également présenté une corrélation positive avec la notation humaine : nous avons relevé une corrélation de Pearson de 0.79 et une corrélation de Spearman de 0.73. Ces valeurs sont très proches de celles obtenues avec QualIT et ROUGE-L, la proximité des scores avec ROUGE-L pouvant sans doute s’expliquer par la construction assez proche des deux métriques.

Visuellement, la dispersion apparaît comparable à celle obtenue avec ROUGE-L, notamment pour les valeurs de scores ROUGE intermédiaires (Figure 20). Les deux métriques semblent donc présenter des comportements très proches.




FIGURE 20 – Score humain selon le score ROUGE-1

Même si ROUGE-L qui prend en compte la plus longue séquence commune, tandis que ROUGE-1 repose uniquement sur le recouvrement lexical en unigrammes, les deux métriques analysent la même dimension de la qualité des extractions, d’où le fait qu’elles présentent des résultats similaires.

Influence des hallucinations L’analyse selon la présence d’hallucinations a pu confirmer la capacité de la métrique ROUGE-1 à détecter efficacement les cas d’erreurs : les contributions annotées comme comportant une hallucination se situaient majoritairement dans la zone de faibles scores (Figure 21). Par comparaison avec ROUGE-L, nous n’avons pas observé de différence qualitative majeure dans la capacité à détecter les hallucinations, les contributions comportant des hallucinations se concentrant majoritairement dans les zones de faibles scores pour les deux métriques.




FIGURE 21 – Score humain selon le score ROUGE-1, coloré selon la présence d'hallucinations

Influence de la longueur des contributions L'effet de la longueur des contributions suivait, de nouveau, une tendance comparable à celle observée avec le score humain (et ROUGE-L) : les textes courts et moyens démontraient en moyenne de meilleurs scores que les textes longs (Figure 22). Néanmoins, nous avons observé un score moyen plus élevé d'environ 0.05 pour les contributions courtes, moyennes et longues avec ROUGE-1 par rapport à ROUGE-L, ce qui a confirmé la sensibilité de ROUGE-1 au recouvrement proportionnel de mots. Dans les contributions plus longues, une omission de mots a une influence moins marquée que pour les contributions très courtes. De par sa construction, ROUGE-1 les pénalise donc moins que ROUGE-L, leur attribuant donc un score légèrement plus élevé.




FIGURE 22 – Score ROUGE-1 moyen selon la longueur des contributions (en tokens)

Dans l'ensemble, ROUGE-L et ROUGE-1 fournissent des résultats cohérents et proches en termes de corrélation avec l'évaluation humaine. ROUGE-1 se distingue par sa simplicité et sa sensibilité au recouvrement lexical direct, tandis que ROUGE-L introduit une contrainte séquentielle supplémentaire. Les deux métriques restent toutefois limitées à une analyse de surface et ne permettent pas, à elles seules, de capturer pleinement les écarts sémantiques plus subtils.

Métrique	Cor. P	Cor. S	Moy.	Méd.	Moy. (H*)	Moy. ($\neg$ H)	Moy. (I**)	Moy. ($\neg$ I)
ROUGE-1	0.79	0.73	0.60	0.66	0.37	0.79	0.71	0.60
ROUGE-L	0.78	0.72	0.56	0.60	0.33	0.75	0.67	0.56

* H = contributions avec hallucinations

** I = présence d'idées séparées.

TABLE 3 – Synthèse quantitative des métriques ROUGE

3.4 Métrique NLI

Pour la métrique NLI, nous nous sommes intéressés à trois scores distincts :

1. Le score moyen d'**entailment** NLI_{support} , qui mesurait le degré de soutien sémantique des extractions par la contribution originale.
2. Le score moyen de 1 – **contradiction** $1 - NLI_{\text{contra}}$, qui pénalisait explicitement les contradictions.
3. Le score combiné défini par $NLI_{\text{final}} = \max(0, \min(1, NLI_{\text{support}} - NLI_{\text{contra}}))$, qui cherchait à combiner ces deux dimensions en favorisant les idées fortement soutenues, tout en pénalisant celles qui présentaient une incompatibilité explicite.

Comme exposé précédemment, le score NLI_{final} intégrait à la fois le soutien sémantique et la pénalisation des contradictions. Pour cette raison, et bien que nous ayons présenté les résultats pour les trois mesures, nous avons principalement étudié les résultats du score NLI_{final} .

De plus, comme évoqué lors de la présentation de la métrique NLI, nous avons adopté deux approches pour le calcul de ces différents scores : une approche approximée, mais ne nécessitant pas l'entraînement d'un réseau de neurones, et une approche se basant sur un réseau de neurones généraliste pré-entraîné. Nous présentons donc les résultats de ces deux approches.

3.4.1 Résultats NLI par approximation

Les trois scores de la métrique NLI ont tous présenté des corrélations plutôt positives avec la notation humaine. Le score NLI_{support} a présenté la corrélation la plus élevée avec une corrélation de Pearson de 0.61 et une corrélation de Spearman de 0.62. Ce résultat semble indiquer que le degré de soutien sémantique constitue un plutôt bon indicateur de la qualité d'extraction. Le score $1 - NLI_{\text{contra}}$ a montré des corrélations beaucoup plus faibles, avec seulement 0.28 pour celle de Pearson et 0.24 pour celle de Spearman. Ainsi, il semble que l'absence de contradiction n'implique pas la bonne qualité des extractions. En ce qui concerne NLI_{final} , nous avons obtenu une corrélation de Pearson de 0.52 et une corrélation de Spearman de 0.51. Ces valeurs nous ont semblé assez "logiques" puisque le score NLI_{final} découle directement des deux autres scores. Globalement, les scores NLI ont présenté des corrélations avec la notation humaine plus faibles que les métriques précédentes.

Malgré une corrélation positive entre NLI_{final} et l'évaluation humaine, nous avons relevé une dispersion notable autour de la droite $x = y$, et principalement un phénomène de sous-notation très fort (Figure 23). Contrairement aux métriques ROUGE, où la dispersion était principalement liée à des phénomènes de recouvrement lexical partiel, la dispersion observée ici semble refléter des cas où le modèle NLI attribue un niveau modéré d'entailment à des extractions pourtant jugées faibles par les annotateurs humains.




FIGURE 23 – Score humain selon le score NLI_{final}

influence des hallucinations En analysant le score NLI_{final} selon la présence d'hallucinations, nous avons pu affiner l'interprétation des résultats obtenus. Malgré la tendance générale à la sous-notation de NLI_{final} , nous avons observé qu'une partie des sur-notations correspondaient à des extractions présentant des hallucinations (Figure 24). Toutefois, cette sur-notation reste assez légère, avec des scores ne dépassant pas les 0.4. Nous avons également relevé qu'une partie des sous-notations sévères, où le score NLI_{final} était fixé à 0, correspondaient à des extractions avec hallucinations. De plus, avec cette métrique, nous ne sommes pas parvenus à observer de séparation aussi distinctes que pour les métriques ROUGE ou QualIT entre les extractions avec et sans hallucinations.




FIGURE 24 – Score humain selon le score NLI_{final} , coloré selon la présence d'hallucinations

Ainsi, la métrique NLI_{final} par la méthode d'approximation ne nous a pas semblé adaptée pour la détection d'hallucinations.

Influence de la longueur des contributions L'analyse de l'influence de la longueur des contributions sur le score NLI_{final} a exhibé une tendance décroissante selon la longueur de la contribution

originale : plus la contribution était longue, plus le score NLI_{final} moyen associé était faible (Figure 25). Cette observation peut sans doute s’expliquer par la construction du score support global qui correspond au meilleur score obtenu sur chacune des phrases de la contribution prises individuellement. Ainsi, les contributions plus longues, dans lesquelles une même idée était souvent développée sur plusieurs phrases ou bien tout au long de la contribution, ont obtenu des scores plus faibles sur l’ensemble des phrases de la contribution et donc un score final plus faible, ce qui conduit à une sous-estimation de NLI_{final} . Tout cela met en avant la dépendance de la métrique NLI au découpage du texte et à la manière dont les idées sont structurées au sein de celle-ci. En outre, les contributions les plus longues augmentent la probabilité d’omissions partielles. Lorsqu’une extraction ne couvre qu’une partie des idées exprimées, certaines d’entre elles obtiennent un support faible sans pour autant constituer des contradictions explicites ou présenter des scores humains notablement plus faibles.




FIGURE 25 – Score NLI_{final} moyen selon la longueur des contributions (en tokens)

3.4.2 Résultats NLI avec RoBERTa

La variante utilisant le modèle pré-entraîné de type RoBERTa a présenté des résultats très similaires en termes de corrélation avec l’évaluation humaine. Nous avons observé que le score $NLI_RoBERTa_{support}$ obtenait les corrélations les plus fortes avec l’évaluation humaine (Pearson = 0.61 et Spearman = 0.62). Inversement, $1 - NLI_RoBERTa_{contra}$ a présenté une corrélation nettement plus faible (Pearson = 0.15 et Spearman = 0.28), confirmant que l’absence de contradiction ne constituait pas en soi un indicateur de qualité robuste. Le score $NLI_RoBERTa_{final}$, combinant support et contradiction, s’est positionné entre les deux scores précédents (Pearson = 0.51 et Spearman = 0.53), traduisant un compromis moins discriminant que le soutien seul.

Ces résultats ont confirmé nos observations avec la métrique NLI par approximation : la qualité des extractions est davantage liée au soutien explicite du texte plutôt qu’à l’absence de contradiction. Autrement dit, les erreurs d’extraction observées relevaient principalement d’un manque d’alignement sémantique avec la contribution initiale plutôt qu’à des contradictions.

De nouveau, et malgré une corrélation positive entre la métrique $NLI_RoBERTa_{final}$ et le score humain, nous avons observé une très forte dispersion des points autour de la droite d’équation $y = x$, avec un phénomène de sous-notation par la métrique NLI (Figure 26). Nous avons relevé deux zones de forte densité. La première, associée à des points au score $NLI_RoBERTa_{final}$ proche

de 0 mais au score humain très variable, nous a permis de supposer que la métrique peinait à discriminer les cas réellement incorrects de cas corrects. La seconde, associée à des points au score $NLI_RoBERTa_{final}$ proche de 1 mais au score humain entre moyen et bon, a laissé suggérer que la métrique avait également une certaine tendance à la sur-notation.




FIGURE 26 – Score humain selon le score $NLI_RoBERTa_{final}$

Globalement, il en est ressorti une certaine incapacité de la métrique à capturer finement la qualité des extractions. Ces résultats étaient très proches de ceux obtenus avec l’approximation, ce qui laisse penser que le passage à un modèle RoBERTa pré-entraîné pour la tâche d’inférence textuelle ne modifie pas radicalement la dynamique observée. Cela suggère que le comportement global dépend davantage du principe même de l’inférence textuelle.

Influence des hallucinations La répartition des hallucinations pour la métrique $NLI_RoBERTa_{final}$ était assez similaire à celle obtenue précédemment pour NLI_{final} . De nouveau, la majorité des extractions contenant des hallucinations ont présenté un score plutôt faible pour le score humain et pour le score $NLI_RoBERTa_{final}$ (Figure 27). Comme pour NLI_{final} , nous avons observé à la fois un phénomène de sur-notation et de sous-notation des contributions contenant des hallucinations. Cependant, davantage d’extraction ne présentant pas d’hallucination et un plutôt bon score humain ont obtenu un score $NLI_RoBERTa_{final}$ faible (< 0.2). Ainsi, nous ne sommes pas parvenus à observer de séparation aussi distincte que pour les métriques ROUGE ou QualIT entre les extractions avec et sans hallucinations : l’analyse du soutien du texte ne parvient pas à capter pleinement ni la présence d’hallucinations ni leur degré.




FIGURE 27 – Score humain selon le score $NLI_RoBERTa_{final}$, coloré selon la présence d’hallucinations

influence de la longueur des contributions Nous avons observé des différences notables entre le score $NLI_RoBERTa_{final}$ moyen selon la longueur de la contribution originale (Figure 28). Les contributions très courtes et courtes (0–100 tokens) ont obtenu des scores moyens relativement élevés (~ 0.45), et nous avons observé une légère diminution ensuite pour les contributions de longueur moyenne (101–200 tokens) (~ 0.39). En revanche, les contributions longues (> 200 tokens) se sont nettement distinguées par une chute importante du score moyen (~ 0.10). Cette dégradation brutale a contrasté avec la métrique NLI initiale, pour laquelle la baisse liée à la longueur apparaissait plus progressive et moins accentuée. Cette différence a suggéré que la version de la métrique NLI avec un RoBERTa pré-entraîné semble donc plus sensible à l’augmentation de la densité informationnelle : lorsque le nombre d’unités d’information croît fortement, le score final (entailment – contradiction) tend à se dégrader rapidement.




FIGURE 28 – Score $NLI_RoBERTa_{final}$ moyen selon la longueur des contributions (en tokens)

Dans l’ensemble, les métriques NLI et $NLI_RoBERTa$ fournissent des résultats globalement cohérents et comparables en termes de corrélation avec l’évaluation humaine. Dans les deux cas, le

score de soutien sémantique apparaît comme le meilleur indicateur de qualité, tandis que l’absence de contradiction seule demeure peu discriminante. La version RoBERTa pré-entraîné ne modifie pas profondément la dynamique observée. De plus, les deux approches présentent des limites similaires : une dispersion très importante, une capacité imparfaite à pénaliser toutes les formes d’hallucinations et une sensibilité à la longueur des contributions. Ainsi, bien que les métriques basées sur l’inférence textuelle dépassent les simples mesures de recouvrement lexical, elles ne semblent pas en capacité de capturer pleinement la complexité qualitative des extractions générées par un LLM et ni d’apporter de véritable plus-value par rapport aux autres métriques. C’est en partie pour cette raison, et aussi pour leur coût computationnel, que nous avons choisi de ne pas les intégrer au pipeline de traitement.

Métrique	Cor. P	Cor. S	Moy.	Méd.	Moy. (H*)	Moy. (¬H)	Moy. (I**)	Moy. (¬I)
$NLI_{support}$	0.61	0.62	0.42	0.40	0.25	0.55	0.50	0.41
$1 - NLI_{contra}$	0.28	0.24	0.84	1.00	0.74	0.91	0.91	0.81
NLI_{final}	0.52	0.51	0.35	0.32	0.16	0.49	0.44	0.33
$NLI_RoBERTa_{support}$	0.54	0.53	0.46	0.35	0.23	0.63	0.53	0.47
$1 - NLI_RoBERTa_{contra}$	0.15	0.23	0.94	0.98	0.92	0.96	0.94	0.95
$NLI_RoBERTa_{final}$	0.51	0.53	0.40	0.29	0.15	0.59	0.48	0.42

* H = contributions avec hallucinations

** I = présence d’idées séparées.

TABLE 4 – Synthèse quantitative des métriques NLI et $NLI_RoBERTa$

Synthèse des résultats pour l’ensemble des métriques

Métrique	Cor. P	Cor. S	Moy.	Méd.	Moy. (H*)	Moy. (¬H)	Moy. (I**)	Moy. (¬I)
Notation humaine	/	/	0.54	0.60	0.28	0.75	0.50	0.62
QualIT	0.71	0.72	0.78	0.85	0.71	0.90	0.82	0.84
ROUGE-1 (F1)	0.79	0.73	0.60	0.66	0.37	0.79	0.71	0.60
ROUGE-L (F1)	0.78	0.72	0.56	0.60	0.33	0.75	0.67	0.56
$NLI_{support}$	0.61	0.62	0.42	0.40	0.25	0.55	0.50	0.41
$1 - NLI_{contra}$	0.28	0.24	0.84	1.00	0.74	0.91	0.91	0.81
NLI_{final}	0.52	0.51	0.35	0.32	0.16	0.49	0.44	0.33
$NLI_Roberta_{support}$	0.54	0.53	0.46	0.35	0.23	0.63	0.53	0.47
$1 - NLI_Roberta_{contra}$	0.15	0.23	0.94	0.98	0.92	0.96	0.94	0.95
$NLI_Roberta_{final}$	0.51	0.53	0.40	0.29	0.15	0.59	0.48	0.42

* H = contributions avec hallucinations

** I = présence d’idées séparées.

TABLE 5 – Synthèse quantitative des métriques : corrélations avec la note humaine et statistiques descriptives.

3.5 Pipeline

Nous avons construit un pipeline avec pour objectif d’avoir un maximum de flexibilité sur sa réutilisation. Nous lui avons donc fourni de nombreux arguments d’entrée, dont les suivants :

- `df` : Le jeu de données à analyser.
- `system_prompt` : Le prompt système pour le LLM.
- `user_template` : Le template utilisateur pour le LLM.

- `extract_model` : Le LLM pour l'extraction (avec par défaut celui que nous avons utilisé, "llama3 :8b-instruct-q4_K_M").
- `embed_model` : le modèle de sentence-transformers pour les embeddings (avec par défaut "sentence-transformers/all-MiniLM-L6-v2").
- `return_intermediate` : un argument binaire pour préciser si nous souhaitons aussi le jeu de données avec l'analyse de sentiments (défaut = False).
- `error_filter` : Un argument binaire pour filtrer ou non les erreurs de parsing (défaut = "Oui").
- `qualit_filter` : Le score QualIT minimal pour qu'une extraction soit conservée (défaut = 0 : pas de filtre).
- `rouge1_filter` : Le score ROUGE 1-gramme minimal pour qu'une extraction soit conservée (défaut = 0 : pas de filtre).
- `rougeL_filter` : Le score ROUGE L minimal pour qu'une extraction soit conservée (défaut = 0 : pas de filtre).

Le pipeline proposé peut être mobilisé de plusieurs manières complémentaires. Tout d'abord, il constitue un cadre expérimental permettant de comparer différents LLM ou différentes stratégies de prompt afin d'évaluer leur capacité à extraire correctement les idées contenues dans les contributions en comparant les scores. Nous nous sommes d'ailleurs servi de cet aspect du pipeline afin d'évaluer l'influence du choix du LLM d'extraction (Cf section suivante). Ce pipeline peut aussi servir à la construction de jeux de données présentant différents niveaux de qualité. En choisissant des seuils plus sévères, il est possible d'obtenir des jeux de données ne contenant que des extractions jugées très fiables. Cet aspect permet de contrôler explicitement le compromis entre couverture et précision.

3.6 Influence du LLM d'extraction

La dernière partie de notre analyse a porté sur l'influence du modèle de langue. Nous souhaitons évaluer si l'utilisation d'un modèle de plus grande capacité pouvait amener à des extractions de meilleure qualité, et également si les métriques étudiées étaient bien sensibles à cette différence de qualité. Pour cela, nous avons utilisé le modèle **Gemini 3 Pro** via *Vertex AI*. L'analyse des 200 contributions et quelques essais préliminaires d'appel du modèle ont représenté un coût total de 5.19€.

La première phase d'annotation manuelle ayant révélé un fort accord entre les trois annotateurs, nous avons décidé pour cette partie de nos travaux qu'un seul annotateur suffirait, notamment afin de gagner du temps.

3.6.1 Comparaison de la qualité des extractions

Nous avons observé une nette amélioration de la qualité des extractions avec le modèle de langue **Gemini 3 Pro** en comparaison du modèle **Llama 8B** utilisé précédemment. En effet, nous avons obtenu un score moyen et un premier quartile (25%) de 0.81 et 0.7 respectivement pour **Gemini 3 Pro**, contre un score moyen de 0.53 pour **Llama 8B** (Figure 29a). Toutefois, nous avons relevé que cette différence de score était essentiellement portée par les contributions très courtes et longues, les contributions courtes et moyennes affichant des scores moyens similaires pour les deux modèles (Figure 29b). Pour les très courtes contributions, nous pensons que cette différence peut s'expliquer par la forte diminution du nombre d'hallucinations qui touchaient beaucoup les très courtes contributions (1 seule avec **Gemini 3 Pro** contre 66 avec **Llama 8B**). Pour les contributions longues, nous avons expliqué cette différence par le fait que **Gemini 3 Pro** s'était montré bien plus efficace dans la synthétisation

des idées, notamment pour les très longues contributions qui contenaient souvent beaucoup d'exemples chiffrés, ce qui a amené à des notes humaines plus élevées.




FIGURE 29 – Comparaison du score humain entre le modèle Llama 8B et Gemini 3 Pro

Le modèle **Gemini 3 Pro** s'est également montré plus performant sur la problématique des idées séparées : nous en avons relevé 24 occurrences, contre 66 avec **Llama 8B**.

Enfin, les quelques erreurs du modèle **Gemini 3 Pro** n'ont pas été des erreurs de parse, comme cela avait pu être le cas avec le modèle **Llama 8B**, mais des erreurs de temps de réponse serveur. Cette problématique n'a touché que 12 contributions, mais les performances du modèle pourraient donc être encore meilleures en essayant de relancer les requêtes n'ayant pas abouti.

3.6.2 Influence sur le score des métriques




FIGURE 30 – Scores ROUGE-1, ROUGE-L et QualIT selon le modèle d'extraction




FIGURE 31 – Scores NLI selon le modèle d’extraction

Nous avons bien obtenu des scores plus élevés pour l’ensemble des métriques que nous avons étudiées, à l’exception de la métrique NLI contradiction, mais qui doit justement être la plus faible possible (Figures 30 et 31). Les métriques parviennent donc bien à mesurer l’amélioration de la qualité des extractions avec le nouveau modèle de langue.

Cette amélioration ne se limite pas à un simple décalage des scores de métriques vers le haut. Nous avons également observé un phénomène de resserrement des scores pour les métriques ROUGE, QualIT et NLI_entailment. Ce resserrement traduit des extractions réalisées par Gemini pro 3 de meilleure qualité, mais aussi plus homogènes (i.e. avec moins de cas de score extrême).

En conclusion, ces résultats mettent en avant un réel intérêt à utiliser un modèle de plus grande taille pour la tâche d’extraction d’idées. L’augmentation du nombre de paramètres du modèle employé pour l’extraction offre une meilleure fidélité sémantique des idées, une diminution significative des hallucinations et une meilleure robustesse des extractions.

4 Enjeux sociétaux et environnementaux

4.1 Politique de la structure d’accueil : Data For Good

Perspectiva, et donc par extension nos travaux, s’inscrit est un projet issu de l’association *Data For Good* [sit26], un collectif rassemblant plus de 7,000 bénévoles (data scientists, data engineers, développeurs, designers, etc.) mettant leurs compétences numériques au service de l’intérêt général. L’association repose sur un modèle collaboratif : les équipes se constituent autour de projets thématiques, souvent en collaboration avec des acteurs publics ou associatifs comme ANTICOR ou OXFAM. Elle concentre son action sur trois axes principaux : i) climat et biodiversité, ii) démocratie et citoyenneté, et iii) justice sociale. Data For Good se positionne explicitement sur des enjeux sociaux et environnementaux majeurs.

Sur le plan écologique, cet engagement se traduit de deux façons. D’une part, plusieurs projets visent directement à produire des outils d’analyse et de transparence sur des problématiques environnementales (surpêche, énergies fossiles, déforestation, enjeux environnementaux de l’alimentation, etc.). D’autre part, son organisation en interne réduit fortement son empreinte écologique : l’absence de locaux permet de supprimer les déplacements récurrents domicile-travail ainsi que les coûts énergétiques liés au chauffage ou à la climatisation, et la coordination au sein des différents projets

est gérée via des outils numériques (GitHub, Slack, etc.). Ainsi, l’empreinte de la structure est faible comparée à celle d’une organisation classique.

Sur le plan social, l’association s’investit dans des projets qui favorisent l’intégration des personnes réfugiées, accompagnent celles en situation de précarité, luttent contre les cyberviolences et les discriminations, ou cherchent à renforcer la transparence démocratique. Les initiatives sur la désinformation, les biais algorithmiques ou la justice fiscale visent à enrichir le débat public et à mieux faire comprendre les mécanismes institutionnels.

Ainsi, la structure dans laquelle s’inscrit notre projet est déjà très vertueuse de par son positionnement et son organisation. Cependant, l’enjeu environnemental du numérique, notamment lorsqu’on utilise le cloud ou des modèles d’intelligence artificielle particulièrement gourmands en ressources, n’est pas totalement négligeable. Pour aller plus loin, il serait pertinent de mesurer précisément l’empreinte écologique de chaque projet ou de définir une politique claire de sobriété numérique.

4.2 Enjeux environnementaux personnels

L’enjeu environnemental de notre projet en tant que tel reste assez limité. L’ensemble des réunions (environ une dizaine, d’une durée d’1h-1h30) se sont toujours déroulées à distance, ce qui a permis d’éviter tout déplacement en voiture ou même en transports en commun. Bien que les visioconférences impliquent une consommation énergétique liée à l’utilisation des ordinateurs et au trafic de données, cette consommation reste généralement inférieure à celle qu’aurait engendré des déplacements répétés, notamment en voiture individuelle.

Pour ce projet, nous avons travaillé sur nos trois ordinateurs personnels. L’électricité consommée correspond à un usage classique : traitement de données, rédaction et réunions en ligne. L’extraction d’idées n’a représenté qu’une très faible partie de notre activité. Aucun de nos équipements n’ayant été acheté spécifiquement pour ce projet, nous ne pouvons donc pas vraiment lui attribuer le coût de leur fabrication.

Pour une partie des traitements, nous avons utilisé des infrastructures distantes, comme Google Cloud Platform (VertexAI), et des services en ligne tels que GitHub ou Google Drive pour l’hébergement des fichiers de code ou les notes de réunions. Ceci implique donc des centres de données et donc de la consommation d’énergie. Bien que l’empreinte de ces services reste modeste, leur usage contribue tout de même à l’empreinte globale du projet.

Le projet s’est également appuyé sur l’utilisation de modèles pré-entraînés pour l’extraction d’idées et pour la seconde partie de la métrique NLI. L’entraînement initial de ces modèles demande beaucoup d’énergie, mais cette empreinte énergétique est partagée entre tous les utilisateurs. Pour notre projet, seule la phase d’inférence compte vraiment, et elle reste très faible vu le nombre limité de contributions et d’idées analysées.

Enfin, nous nous sommes appuyés sur des outils d’intelligence artificielle pour nous assister dans l’écriture de code et la rédaction du rapport. Ces outils impliquent une consommation énergétique supplémentaire, néanmoins, nous avons essayé d’en faire une utilisation plutôt sobre en y recourant qu’en cas de véritable blocage et non pas comme premier réflexe.

Dans l'ensemble, l'empreinte environnementale du projet à petite échelle provient principalement de la consommation électrique des équipements informatiques et de l'usage d'infrastructures cloud.

4.3 Enjeux environnementaux globaux

Même si l'empreinte environnementale directe de notre projet reste modérée, nous ne pouvons pas nous limiter à cette observation. En effet, notre projet s'inscrit dans un écosystème numérique plus large, dont l'empreinte est significative, en particulier à cause des grands modèles de langue (LLM). La principale partie des dépenses énergétiques ont lieu en amont, lors de l'entraînement initial de ces modèles, très coûteux en ressources (électricité, matériel spécialisé, eau, fonctionnement des centres de données et de calcul, etc.). Même si ce coût est mutualisé par un nombre important d'utilisateurs, il reste la composante la plus lourde de l'empreinte de ces outils et ne peut pas être négligé.

Nos résultats ont aussi montré une différence de qualité notable entre petits et grands modèles, ce qui incite donc indirectement à l'utilisation de modèles plus volumineux, et donc plus coûteux en ressources. Pour un usage ponctuel comme dans notre projet, cette dépense en ressources supplémentaire reste limitée. En revanche, si ce type de pipeline était déployé de manière généralisée ou à grande échelle (augmentation des consultations ou nombres très importants de contributions par exemple), l'empreinte cumulée pourrait devenir lourde.

Nous pouvons faire le même constat pour le choix de la métrique à utiliser : les traitements de la métrique QualIT, des métriques ROUGE et de la métrique NLI "à la main" sont locaux et assez peu coûteux, mais l'usage de la métrique NLI avec le modèle pré-entraîné repose sur un coût environnemental significatif pour son entraînement. En principe, il serait possible de réduire cette dépense en développant localement un modèle plus petit adapté spécifiquement à la consultation considérée. Toutefois, cela demande également du temps, des compétences, et des exemples déjà annotés, ce qui n'est pas forcément compatible avec les contraintes des consultations publiques, et peut même aller dans le sens inverse de l'objectif initial de gain de temps.

Ainsi, l'enjeu environnemental ne se situe pas seulement dans la consommation énergétique directe de notre projet, mais surtout dans l'écosystème dans lequel il s'inscrit à plus grande échelle : la diffusion et la banalisation de pratiques coûteuses (LLM, modèles pré-entraînés, traitements automatisés, etc.). Le fait qu'un usage isolé présente un faible enjeu environnemental ne suffit pas à blanchir un projet, dès lors qu'il contribue, même faiblement, à la banalisation d'outils augmentant la demande en ressources numériques et environnementales. Cela invite finalement à une forme de responsabilité collective : choisir les modèles avec soin, les utiliser de manière réfléchie et sobre et garder en tête le rapport entre les bénéfices de leur utilisation et leur consommation lors de l'entraînement et de l'utilisation.

4.4 Enjeux sociaux globaux

À l'instar des enjeux environnementaux, les enjeux sociaux directs de notre projet sont assez faibles. Notre travail n'a conduit à aucun déploiement d'outil de décision collective ou de dispositif disponible pour le grand public. Néanmoins, notre travail s'inscrit dans le projet *Perspectiva*, et plus largement dans le secteur des outils numériques pour l'analyse de consultations publiques. En cherchant encore

plus large, il s'inscrit dans le développement de la démocratie participative à l'aide de méthodes computationnelles. Autrement dit, notre projet en lui-même n'a aucun enjeu social, mais l'écosystème plus général dans lequel il s'inscrit est intrinsèquement politique et peut avoir des répercussions sociales importantes.

À court terme, une perspective vertueuse de ce type d'outils est d'accompagner la décision publique. Comme exposé en introduction, l'objectif n'est pas de remplacer les décideurs et analystes, mais de mieux transmettre les idées, préoccupations et positions des citoyens, notamment lorsque le volume ou la longueur des contributions rend l'analyse manuelle lente, difficile et coûteuse. Ces outils aident ainsi à mieux écouter les individus et à restituer la parole collective de façon plus structurée. Ils peuvent aussi aider à redynamiser le débat public, notamment dans un contexte marqué par une défiance envers les institutions, de polarisation des discours, et où beaucoup ont le sentiment de ne plus être entendus. Mais ceci n'a de sens que si les résultats des consultations publiques sont réellement pris en compte et intégrés à la prise de décision. À défaut, l'amélioration de ces outils risque de renforcer ce sentiment de consultation "symbolique" plutôt que réellement utile.

À plus long terme, ces outils peuvent aussi ouvrir de nouveaux horizons. Nous pouvons imaginer qu'ils participent à transformer les modèles de gouvernance actuels vers des modèles plus horizontaux et plus participatifs. Bien sûr, ce ne sera ni forcément le cas, ni souhaitable dans tous les contextes, mais développer de nouveaux dispositifs pour traiter automatiquement la parole citoyenne encourage la mise en œuvre de nouvelles possibilités politiques. En ce sens, nous pouvons voir cela comme une épée à double tranchant : elle peut amener des avancées démocratiques intéressantes (davantage d'inclusion, des débats plus riches, des consultations plus fréquentes, etc), au risque de dérives (simplification des idées à l'extrême, délégation excessive, décisions opaques, etc). En l'encourageant, il est donc tout de même important de maintenir une certaine vigilance vis-à-vis du développement de ce type d'outils.

Un premier enjeu central pour ces outils est celui de la représentativité. Même si les outils développés fonctionnent très bien, une consultation reste fragile si elle n'atteint qu'une petite partie de la population. Cela a notamment été reproché au Grand Débat National [Bli19, BGM20], et nous l'avons aussi partiellement constaté à la lecture des contributions : certains groupes sociaux sont plus présents (retraités, diplômés, propriétaires, etc), sans doute car plus à l'aise avec les formats de réponse proposés ou plus disponibles pour répondre. Dans ce contexte, les outils développés peuvent contribuer soit à réduire, soit au contraire à renforcer certains biais, leur influence dépendant moins de la qualité de l'extraction que de la composition sociale des contributeurs-rices. Il serait donc pertinent que les dispositifs de restitution intègrent, autant que possible, une réflexion explicite sur la représentativité des répondants ou, a minima, un signalement des déséquilibres observés. Cela permettrait de limiter le risque de présenter un point de vue socialement situé comme s'il représentait la "voix citoyenne" dans son ensemble.

La problématique de représentativité est étroitement liée à celle de la fracture numérique. Lorsque la collecte des contributions repose majoritairement sur des dispositifs en ligne, une partie de la population appelée à contribuer peut se retrouver mise de côté : ceux qui n'ont pas l'équipement, ceux qui ne sont pas à l'aise avec le numérique, les personnes âgées, etc. Dans le cas du Grand Débat National, sur lequel s'est appuyé notre projet, plusieurs modes de participation étaient mis à disposition – plateforme en ligne, réunions publiques et cahiers en mairie – ce qui a permis de réduire l'influence de la fracture numérique. De nouveau, ces outils doivent donc être utilisés en gardant cette

problématique en tête afin d’avoir une influence sociale positive en évitant d’exclure une partie de la population du débat public.

Un second enjeu majeur concerne les biais potentiels liés au choix du LLM et, plus largement, des données sur lesquelles il a été entraîné. Les grands modèles de langue sont entraînés sur d’immenses corpus qui peuvent contenir, explicitement comme implicitement, des discours sexistes, racistes, classistes, etc. Un modèle pourrait, par exemple, mieux reconnaître ou valoriser certains de ces discours au détriment d’autres. Dans un contexte politique, et notamment de décision publique, la façon dont sont construits les outils numériques utilisés peut avoir des répercussions importantes si ce type de biais passait sous le radar des métriques, influençant la synthèse finale et, in fine, les décisions publiques.

Au-delà des performances et des biais, un autre enjeu notable est l’acceptabilité sociale de ces outils, qui dépend directement de leur transparence et de leur accessibilité. Dans des contextes politiques sensibles, il semble essentiel d’éviter que ces outils soient perçus comme des "boîtes noires" qui imposent des résultats sans explication. Pour que ces outils soient adoptés et puissent apporter une véritable plus-value, il est nécessaire que les objectifs, les limites, les étapes de traitement et les critères d’évaluation soient présentés et expliqués, afin de créer une forme de confiance dans ces outils. Cependant, cette exigence de transparence ne doit pas se transformer en une mécanisation excessive du débat : il est tout aussi important de rendre ces outils compréhensibles et utilisables, sans exiger des utilisateurs (e.g. employés d’une mairie) des compétences avancées en codage ou en apprentissage statistique. La simplicité de déploiement, la clarté des résultats et leur robustesse comptent autant que la qualité algorithmique pour que ces outils soient réellement utilisés.

Enfin, la question de la gestion des données et de leur hébergement constitue un enjeu social et politique important. Beaucoup de dispositifs respectent déjà un cadre réglementaire (notamment le RGPD), et ceci doit bien entendu être maintenu. Toutefois, ce n’est pas la problématique vis-à-vis des données de consultations publiques. L’utilisation de LLM à distance implique l’envoi de contributions citoyennes vers des infrastructures opérées par des entreprises privées, parfois situées à l’étranger. Dans un contexte de décision publique, cette utilisation peut soulever des questions de confidentialité, de dépendance technologique et, plus largement, de souveraineté numérique. Une alternative serait d’utiliser des modèles exécutés localement. Cela réduirait les transferts de données, mais limiterait également l’accès aux modèles les plus performants. Ce compromis entre performance, maîtrise des données et autonomie est donc un point important du développement d’outils numériques pour les consultations publiques.

En somme, l’enjeu social global de notre projet ne se situe pas dans ses effets immédiats, qui sont concrètement nuls, mais dans les enjeux des outils plus généraux auxquels il se rattache. En s’inscrivant dans une réflexion plus large sur l’utilisation d’outils numériques pour la participation citoyenne, ce projet engage des questions de représentativité, de biais algorithmiques, de transparence des processus, d’accessibilité des outils et de souveraineté des données, qui peuvent tout autant avoir des conséquences sociales positives que négatives.

5 Conclusion

Ce projet tutoré s’était donné pour objectif de mesurer la qualité des extractions d’idées réalisées par un LLM, notamment dans le cadre du traitement de consultations publiques. À travers l’analyse

de 200 contributions issues du Grand Débat National, nos travaux se sont articulés autour de trois axes majeurs : l’analyse comparative de métriques de performance, la conception d’un pipeline de traitement systématique, et l’étude de l’influence du modèle de langue sur la fiabilité des sorties.

L’expérimentation, menée sur trois familles de métriques, a permis de dégager des conclusions contrastées quant à leur capacité à mesurer la qualité de l’extraction par rapport à une évaluation humaine. Les métriques lexicales, ROUGE-1 et ROUGE-L, ont présenté les corrélations les plus élevées (0.79 et 0.78). Bien qu’elles soient sujettes à des phénomènes de sur-notation et de sous-notation pour les extractions de qualité intermédiaire, elles se sont avérées assez performantes pour détecter les hallucinations, et ce même de manière nuancée.

La métrique QualIT a montré des résultats légèrement moins intéressants, avec une corrélation de 0.71, une propension à la sur-notation et une difficulté à identifier les hallucinations. Cependant, cette métrique offre une approche sémantique intéressante, en se basant sur la similarité des idées au travers des embeddings plutôt que la stricte concordance des mots comme les métriques ROUGE. Bien qu’imparfaite, ceci en fait donc une piste intéressante, notamment si couplée aux autres métriques ROUGE.

Les résultats concernant les métriques de Natural Language Inference se sont révélés plus décevants, avec des corrélations stagnantes autour de 0.51 et 0.52 pour la version finale et au mieux de 0.61 en prenant en compte seulement l’entailment. Leur forte dispersion, leur sensibilité à la longueur des contributions et leur incapacité à pénaliser les différentes formes d’hallucinations avec nuance limitent leur valeur ajoutée par rapport aux mesures de recouvrement lexical ou à la métrique QualIT.

Le pipeline développé ensuite en utilisant les métriques QualIT, ROUGE-1 et ROUGE-L, constitue un cadre expérimental que nous espérons le plus complet possible pour la suite du projet *Perspectiva*. Il permet de comparer différents prompts et différents modèles, et offre également un contrôle sur la qualité des idées extraites. En ajustant les seuils de sélection sur chaque métrique, les futurs utilisateurs pourront alors faire le choix entre la précision (ne conserver que les extractions de haute qualité) et la couverture (maintenir le plus d’idées).

En parallèle, l’étude de l’influence du choix du modèle d’extraction a clairement mis en évidence l’intérêt d’utiliser des LLM de plus grande taille pour réaliser nos extractions. Le passage de Llama 8B à Gemini 3 Pro a entraîné une amélioration significative de la qualité des extractions, notamment sur les contributions très courtes ou très longues, grâce à un nombre plus faible d’hallucinations et une meilleure capacité de synthèse. De plus, cette étude nous a permis de mettre en lumière la capacité des métriques à capter cette amélioration.

Toutefois, ces résultats et ces outils présentent des limitations. Premièrement, notre échantillon n’était constitué que de seulement 200 contributions, et ne permet donc pas de conclure de manière définitive quant à la qualité des métriques que nous avons étudiées. Néanmoins, ces résultats peuvent être pris comme des indications préliminaires de la pertinence de chaque métrique, qui appellent potentiellement à être confirmées sur un échantillon de plus grande taille ou sur un sujet différent. Deuxièmement, l’utilisation du pipeline est intéressante, mais aboutira nécessairement à un compromis soit sur la qualité des extractions, soit sur leur nombre, au risque de la perte d’idées pertinentes.

Au-delà de ces aspects techniques, il convient de souligner que si notre outil présente des en-

jeux environnementaux directs faibles, il s'inscrit dans un écosystème technologique dont les répercussions ne sont pas négligeables au travers de la généralisation de l'utilisation de modèles de grande taille et de serveurs de données distants. Sur le plan social, l'automatisation du débat public doit être abordée avec vigilance concernant la transparence des algorithmes, la présence de biais dans les outils utilisés, l'accessibilité des outils et la souveraineté numérique, afin de ne pas introduire de nouveaux biais dans le débat public.

L'aboutissement de ce travail ouvre plusieurs voies d'amélioration et d'exploration potentielles. Tout d'abord, l'optimisation des prompts par l'intégration d'exemples d'erreurs types (hallucinations ou mauvaises séparations) pourrait améliorer la précision des extractions. De plus, une étude approfondie de l'influence des seuils de qualité sur la génération des méta-idées dans la seconde partie du projet *Perspectiva*. Enfin, au sein de l'ensemble du projet *Perspectiva*, porter une attention particulière aux idées proposées par les populations sous-représentées parmi les contributeurs pour qu'elles ne soient pas toutes écartées par les filtres de qualité et bien conservées par la suite dans les méta-idées, afin de garantir l'intégrité et l'inclusivité du processus démocratique numérique.

Références

- [AB22] Elisabeth Algava and Kilian Bloch. Vingt ans de participation électorale : en 2022, les écarts selon l'âge et le diplôme continuent de se creuser. <https://www.insee.fr/fr/statistiques/6658143>, 2022.
- [BCR26] Damien Bol, Bruno Cautrès, and Luc Rouban. La défiance envers les politiques en france approche un point de non-retour, selon le baromètre cevipof. *Le Monde*, 2026.
- [BGM20] Hamza Bennani, Pauline Gandré, and Benjamin Monnery. Les déterminants locaux de la participation numérique au grand débat national : une analyse économétrique. *Revue Economique*, 71 :715–737, 2020.
- [Bli19] Simon Blin. Un public éloigné des traits sociologiques des gilets jaunes. *Libération*, 2019.
- [BM19] Eric Buge and Camille Morio. Le grand débat national, apports et limites pour la participation citoyenne. *Revue du droit publique*, pages 1205–1238, 2019.
- [BNC26] Rasmus Blanck, Bill Noble, and Stergios Chatzikyriakidis. Reverse-engineering nli : A study of the meta-inferential properties of natural language inference. /, 2026.
- [Cou20] Dimitri Courant. La convention citoyenne pour le climat. une représentation délibérative. *Revue Projet*, 378 :60–64, 2020.
- [Cyr] François Cyril. Perspectiva - utiliser les outils llm pour analyser et fournir un retour plus rapide et fidèle aux contributeurs d'une consultation publique - enjeux sur la communication des résultats. https://docs.google.com/presentation/d/1z22FzVRVmvVikUffME6vtDrgkIA5p9acvcq-KzoHZ0/edit?slide=id.g35890f26d4e_0_48#slide=id.g35890f26d4e_0_48.
- [Ins26] AI Objectives Institute. Talk to the city. <https://ai.objectives.institute/talk-to-the-city>, 2026.
- [KGB⁺24] Satya Kapoor, Alex Gil, Sreyoshi Bhaduri, Anshul Mittal, and Rutu Mulkar. Qualitative insights tool (qualit) : Llm enhanced topic modeling. /, 2024.
- [Lin04a] Chin-Yew Lin. Rouge : A package for automatic evaluation of summaries. In *Proceedings of the ACL Workshop on Text Summarization Branches Out*, pages 74–81, Barcelona, Spain, 2004.
- [Lin04b] Chin-Yew Lin. Rouge : A package for automatic evaluation of summaries. In *Proceedings of the Workshop on Text Summarization Branches Out (WAS 2004)*, 2004.
- [Rei25] Ehud Reiter. How to validate metric. <https://ehudreiter.com/2018/07/10/how-to-validate-metrics/>, 2025.
- [sit26] Data for good - bâtir un contre-pouvoir tech citoyen. <https://dataforgood.fr/>, 2026.
- [WTC26] E.Glen Weyl, Audrey Tang, and Plurality Community. Plurality : The future of collaborative technology and democracy. <https://www.plurality.net/v/eng/>, 2026.

6 Annexe

But: extraire les idées principales DISTINCTES d'un texte pour analyse.

Règles:

1. N'utiliser QUE le contenu entre «<TEXT >».
2. Extraire la liste des idées DISTINCTES et PRINCIPALES.
 - Chaque idée = une phrase claire, autonome, reformulée si nécessaire.
3. Pour CHAQUE idée, annoter:
 - type: "statement" (constat) OU "proposition" (suggestion/recommandation/objectif).
 - syntax: "negative" si la phrase contient une négation explicite (ex.: "ne", "n'", "ne pas", "ne plus", "non"), sinon "positive".
 - semantic: "positive", "negative" ou "neutral" (valence sémantique).
4. Sortie STRICTEMENT en CSV avec entête EXACTE:
 - Délimiteur: virgule.
 - Chaque description entre guillemets doubles.
 - Chaque description entre guillemets doubles.
 - Échapper tout guillemet interne par duplication (ex.: "\"chat\"").
 - NE RIEN AJOUTER d'autre (pas de texte avant/après, pas de code fences).
 - Pas de lignes vides.

Exemple:

CSV:description,type,syntax,semantic

"Les chats retombent sur leurs pattes",statement,positive,neutral

"Les chats n'ont pas neuf vies",statement,negative,negative

"Il faut mieux prendre soin des chats pour prolonger leur
vie",proposition,positive,positive

FIGURE 32 – Prompt utilisé pour l'extraction d'idées




FIGURE 33 – Distribution du score humain