

1 Objectif

À partir des entrées que vous avez faites sur RedCAP, on peut mener une analyse statistique en extrayant un tableur contenant les données de chaque patient appelé jeu de données. Pour mener correctement ce type d'étude, il faut respecter deux grandes étapes :


- Comprendre les caractéristiques (poids, âge, ...) de l'échantillon obtenu avec des statistiques descriptives.
- Mesurer l'effet du médicament ou de la cure sur la pathologie étudiée au travers de tests statistiques.

Dans notre cas, on souhaite voir si la cure a permis d'améliorer la qualité de vie du patient et de réduire la sévérité de l'asthme selon le patient et selon le médecin.

1.1 Statistiques descriptives

Les statistiques descriptives sont une étape d'exploration indispensable avant toute analyse ou modélisation. Elles permettent de :

- Faire le résumé d'un grand volume de données avec des indicateurs simples (moyenne, médiane, ...) et des visualisations parlantes.
- Identifier d'éventuelles valeurs aberrantes ou erreurs de saisie (ex. : un humain pesant 3 kg) qui pourraient biaiser les analyses ultérieures.



À vous d'essayer :

- ☐ Indicateurs statistiques classiques : moyenne, médiane, min, max et quantiles.
- ☐ Histogrammes ou boxplots des variables continues (âge, poids, etc).
- ☐ Diagramme en barre des variables catégorielles (sexe, antécédents familiaux, etc).

Pensez bien à rendre vos figures lisibles (titres, axes, couleurs, etc).

1.2 Tests statistiques

Pour mesurer l'effet d'un traitement (ou d'une cure), on compare les valeurs mesurées à l'inclusion (au début de l'étude) avec celles mesurées après 6 mois. Dans la plupart des cas, on observe des différences, et le but du statisticien est alors de déterminer si elles sont dues au traitement (ou la cure) ou simplement au hasard.


Pour répondre à cette problématique, on utilise des tests statistiques. Le concept peut paraître compliqué,

mais l'idée derrière est relativement simple : on se place dans un cas où le traitement n'aurait aucun effet, puis on se demande quelles différences pourrait-on observer uniquement à cause du hasard ?

Dans le cadre de notre étude, on regarde la différence entre les moyennes des deux mesures (score de qualité de vie ou score de sévérité de l'asthme avant et après traitement). Si le traitement n'a aucun effet, on s'attend à ce que les deux moyennes soient proches et donc que la différence entre elles soit proche de 0. Bien sûr, des petites différences peuvent apparaître naturellement à cause du hasard, mais de grandes différences sont plus rares et pourraient être le signe de l'effet du traitement.

On va donc chercher à évaluer quel point la différence que l'on observe est rare (peu probable), c'est la p-valeur : la probabilité d'observer une différence au moins aussi extrême que celle mesurée, si le traitement n'avait en réalité aucun effet (c'est ce qu'on appelle l'hypothèse nulle). Plus la p-valeur est petite, moins il est plausible que la différence observée soit due au hasard seul. En pratique, on compare la p-valeur à un seuil (souvent 5%) : si elle est inférieure à ce seuil, on considère que la différence est suffisamment improbable pour qu'elle soit due au hasard, et on conclut à un effet significatif du traitement.

À vous d'essayer :



- ☐ Avec l'effet du traitement, s'attend-on à une amélioration ou une détérioration du score de qualité de vie des patients et de la sévérité de l'asthme ? Les scores doivent-ils baisser ou augmenter ?
- ☐ Évaluer la différence entre la qualité de vie des patients à l'inclusion et après 6 mois. Le traitement a-t-il un effet significatif ?
- ☐ Évaluer la différence entre la sévérité de l'asthme selon les patients à l'inclusion et après 6 mois. Le traitement a-t-il un effet significatif ?
- ☐ Évaluer la différence entre la sévérité de l'asthme selon le médecin à l'inclusion et après 6 mois. Le traitement a-t-il un effet significatif ?

1.3 Bonus : régression linéaire

Un autre grand classique des analyses statistiques est la régression linéaire. L'objectif est de mesurer l'intensité et le sens (positif ou négatif) de la relation entre une variable à expliquer (y) et une variable explicative (x). On cherche à déterminer les coefficients de la relation $y = ax + b$ avec a le coefficient directeur et b l'ordonnée à l'origine.

On va faire un exemple sur le jeu de données **cars**. On va étudier la relation entre la vitesse de la voiture (**speed**) et la distance dont elle a besoin pour s'arrêter (**dist**).

À vous d'essayer :

- ☐ Charger le jeu de données **cars**
- ☐ Calculer les coefficients du modèle de régression linéaire.
- ☐ Visualiser les données et la droite de régression.

2 Cheat sheet R

2.1 Utilitaires

- En R, pour assigner une valeur à une variable on utilise "<=". C'est comme le "=" en Python.
- Pour charger un fichier `.csv` (un tableur), on peut utiliser la fonction `read.csv()` en précisant le chemin d'accès au fichier.

```
1 df <- read.csv("../")
```

- Afin de voir vos données sous forme de table, vous pouvez cliquer sur son nom dans la fenêtre en haut à droite ou bien utiliser la commande `View()`.

```
1 View(df)
```

- Pour accéder aux valeurs d'une colonne, on utilise la commande `$` précédée du nom de la table et suivi du nom de la colonne.

```
1 df$age
```

- Pour plus de détails sur une fonction, n'hésitez pas à utiliser la commande `?` suivi du nom de la fonction. La fenêtre en bas à droite ouvrira la documentation de la fonction.

```
1 ?table
```

2.2 Statistiques descriptives

- La fonction `summary()` donne un petit résumé d'un objet. On peut l'utiliser sur une table entière ou sur une seule colonne.

```
1 summary(...)
```

- La fonction `hist()` permet de construire un histogramme. Vous pouvez préciser si vous voulez les fréquences ou les densités avec `freq=...`. Vous pouvez tester les deux pour reprérer la différence.

```
1 hist(x, freq=FALSE)
2 hist(x, freq=TRUE)
```

- Avec `boxplot()`, on peut visualiser la distribution des valeurs avec une "boite moustache".

```
1 boxplot(x)
```

- En combinant les fonctions `barplot()` et `table()`, on peut construire un diagramme en barre.

```
1 barplot(table(x))
```

- Un graphique est toujours plus compréhensible avec un titre et des axes lisibles ! Vous pouvez modifier les paramètres graphiques avec les arguments `main`, `cex.main`, `cex.labs` et autres. N'hésitez pas à vous aider de la documentation.

2.3 Tests statistiques

Pour faire un test de Welch entre deux listes de valeurs **x** et **y**, on utilise la fonction `t.test()`.

```
1 t.test(x, y, alternative="...")
```

On doit également lui préciser l'hypothèse alternative que l'on souhaite étudier, il y a plusieurs possibilités.

- On suppose que les valeurs de **y** sont plus grandes que celles de **x** et que $\bar{x} - \bar{y}$ est inférieur à 0 : `alternative="less"`.
- On suppose que les valeurs de **y** sont plus petites que celles de **x** et que $\bar{x} - \bar{y}$ est supérieur à 0 : `alternative="greater"`.
- On suppose que les valeurs de **y** sont différentes de celles de **x** et que $\bar{x} - \bar{y}$ est différent de 0 : `alternative="two.sided"`.

2.4 Régression linéaire

- Pour charger le jeu de données `cars`, on utilise la fonction `data()`.

```
1 data(cars)
```

- L'affichage du nuage de point se fait avec la fonction `plot(x,y)` où **x** est la liste des valeurs pour l'axe des abscisses et **y** est la liste des valeurs pour l'axe des ordonnées. Chaque point sera affiché à la coordonnée (x_i, y_i) .

```
1 plot(x,y)
```

- On peut ajouter une droite de la forme $ax + b$ avec la fonction `curve()` en précisant `add=TRUE`.

```
1 curve(a*x+b, add=TRUE, col="red")
```

- Pour construire un modèle linéaire ($y = ax + b$), on utilise la fonction `lm()`. Il faut lui préciser une formule et un jeu de données. La fonction `summary()` permet d'avoir des informations sur le modèle construit.

```
1 model <- lm(y~x, data=...)  
2 summary(model)
```

- L'accès aux coefficients du model se fait avec la commande `$coefficient[...]` en précisant le numéro du coefficient. Attention, en R les listes commencent à 1 et non pas à 0 comme en Python.

```
1 model$coefficients[1]
```